

Trabajo de Fin de Grado

Grado en Ingeniería Informática

Ingeniería de Software

Título del trabajo

Martín López de Ipiña Muñoz

Dirección

Galdos Otermin, Aritz

Pereira Varela, Juanan

Azanza Sesé, Maider

8 de mayo de 2025

Resumen

Índice de contenidos

Índice de contenidos	III
Índice de figuras	VII
Índice de tablas	VIII
Índice de algoritmos	1
1 Introducción	1
2 Antecedentes	3
2.1. Onboarding en proyectos software	3
2.1.1. Trabajo previo	4
2.2. Agentes de Grandes Modelos de Lenguaje (LLM)	4
2.2.1. Modelos LLM	4
2.2.2. Interacción con herramientas externas	5
2.2.3. Abstracciones en frameworks	6
2.3. Model Context Protocol	7
2.4. Estado del arte en arquitecturas de agentes LLM	9
2.4.1. Arquitectura RAG	9
2.4.2. Arquitecturas de interacción entre agentes	10
2.5. Agentes LLM en proyectos software	11
2.6. Ajuste de modelos para agentes LLM	13
2.6.1. Limitaciones de los modelos actuales	13
2.6.2. Enfoques de ajuste fino para agentes específicos	13
2.6.3. Técnicas de entrenamiento eficiente	14
3 Planificación	15
3.1. Alcance	15
3.1.1. Objetivos concretos del proyecto	15
3.1.2. Requisitos	16
	III

3.1.3.	Fases del proyecto	16
3.1.4.	Descomposición de tareas	17
3.2.	Periodos de realización de tareas e hitos	20
3.2.1.	Dependencias entre tareas	20
3.2.2.	Diagrama de Gantt	21
3.2.3.	Hitos	21
3.3.	Gestión del tiempo	22
3.3.1.	Estimación de cada tarea	22
3.4.	Gestión de riesgos	22
3.5.	Gestión de Comunicaciones e Información	24
3.5.1.	Sistema de información	24
3.5.2.	Sistema de comunicación	24
3.6.	Herramientas disponibles	24
4	Captura de requisitos	29
4.1.	Requisitos principales	29
4.1.1.	Requisitos funcionales	29
4.1.2.	Requisitos no funcionales	30
4.2.	Dominios de conocimiento	31
4.2.1.	Anotación de preguntas	31
4.2.2.	Metodología empresarial	32
4.3.	Recursos a utilizar	33
4.3.1.	Proyecto software	33
4.3.2.	Recursos generados	33
5	Diseño del sistema	35
5.1.	Estructura del proyecto	35
5.2.	Diseño de agentes	37
5.2.1.	Diagrama de agentes	37
5.3.	Servidores MCP utilizados	40
5.3.1.	Servidores SSE	40
5.3.2.	Servidores STUDIO	42
5.4.	Cliente MCP	44
6	Agentes especializados	49
6.1.	Estructura SpecializedAgent	49
6.1.1.	Gestión de herramientas	51
6.2.	Agentes implementados	51
6.2.1.	Agente código	51
A	Definición de términos técnicos	55

A.1. Conjunto de datos etiquetados	55
A.2. Entrenamiento de redes neuronales	55
A.3. Distancia coseno	56
A.4. Tokenizador	56
B Elicitación de preguntas	57
C Actas de reuniones	67
A.1. Acta de reunión TFG (25/02/2025)	67
A.1.1. Orden del día	67
A.1.2. Resumen de la reunión	68
A.1.3. Estado del proyecto	68
A.1.4. Decisiones	68
A.2. Acta de reunión TFG (12/03/2025)	69
A.2.1. Orden del día	69
A.2.2. Resumen de la reunión	69
A.2.3. Estado del proyecto	70
A.2.4. Decisiones	70
A.3. Acta de reunión TFG (20/03/2025)	71
A.3.1. Orden del día	71
A.3.2. Resumen de la reunión	71
A.3.3. Estado del proyecto	71
A.3.4. Decisiones	72
A.4. Acta de reunión TFG (02/04/2025)	73
A.4.1. Orden del día	73
A.4.2. Resumen de la reunión	73
A.4.3. Estado del proyecto	73
A.4.4. Decisiones	74
A.5. Acta de reunión TFG (04/04/2025)	75
A.5.1. Orden del día	75
A.5.2. Resumen de la reunión	75
A.5.3. Decisiones	75
A.6. Acta de reunión TFG (15/04/2025)	77
A.6.1. Orden del día	77
A.6.2. Resumen de la reunión	77
A.6.3. Estado del proyecto	77
A.6.4. Decisiones	78
A.7. Acta de reunión TFG (29/04/2025)	79
A.7.1. Orden del día	79
A.7.2. Resumen de la reunión	79
A.7.3. Estado del proyecto	80

A.7.4. Decisiones	80
Bibliografía	81

Índice de figuras

2.1.	Ejemplo de interacción de un modelo LLM con una herramienta externa.	6
2.2.	Esquema de funcionamiento del Model Context Protocol.	8
2.3.	Esquema de funcionamiento de la arquitectura RAG en un LLM Fuente.	9
3.3.	Diagrama de Gantt del proyecto	21
3.1.	Estructura de Descomposición de Trabajo (EDT) del proyecto	26
3.2.	Dependencias entre tareas del proyecto	27
3.4.	Estimación horaria de cada tarea	28
5.1.	Estructura de directorios principales del proyecto	36
5.2.	Diagrama de clases UML de del sistema de agentes.	38
6.1.	Grafo de ejecución de agentes especializados	50
6.2.	Diagrama relacional de la base de datos con el código fuente del proyecto software . .	52
6.3.	Algoritmo de chunking considerando definiciones de funciones y clases en el código fuente	53

Índice de tablas

3.1. Cronograma de Hitos del Proyecto	22
C.1. Tareas asignadas (25/02/2025)	68
C.2. Tareas asignadas (12/03/2025)	70
C.3. Tareas asignadas (20/03/2025)	72
C.4. Tareas asignadas (02/04/2025)	74
C.5. Tareas asignadas (04/04/2025)	76
C.6. Tareas asignadas (15/04/2025)	78
C.7. Tareas asignadas (29/04/2025)	80

CAPÍTULO

1



Introducción

Antecedentes

Una vez establecido el objetivo de este proyecto en la introducción, en este capítulo se describirán los conceptos generales necesarios para la comprensión de este documento. Para ello, en primer lugar se detalla el proceso de onboarding en proyectos software y las dificultades que presenta, junto con el trabajo previo realizado en este ámbito.

Por otro lado, se explicará a grandes rasgos qué son los agentes basados en grandes modelos de lenguaje (conocidos también por el anglicismo Large Language Models o por sus siglas LLM), su arquitectura, funcionamiento e interacción con herramientas externas. Se introduce además el Model Context Protocol como estándar de comunicación entre estos componentes.

Finalmente, se aborda el estado del arte en arquitecturas de agentes, sus aplicaciones en proyectos software y las técnicas de ajuste de modelos.

2.1. Onboarding en proyectos software

El proceso de incorporación (onboarding) de nuevos desarrolladores de software constituye un desafío persistente para las organizaciones tecnológicas, donde los recién incorporados enfrentan una sobrecarga informativa mientras los desarrolladores senior ven afectada su productividad al destinar tiempo considerable a actividades de formación y mentoría[1].

Si bien prácticas como la designación de mentores han demostrado ser efectivas para facilitar la integración de nuevos miembros, estas incrementan significativamente la carga de trabajo sobre los profesionales experimentados, generando potenciales retrasos en los proyectos[2].

En este contexto, los modelos de lenguaje de gran escala emergen como una alternativa prometedora para transformar el proceso de onboarding, ofreciendo orientación personalizada e

instantánea que podría reducir la dependencia de los desarrolladores senior, preservar la productividad global de los equipos y facilitar una incorporación más eficiente y menos disruptiva[3].

2.1.1. Trabajo previo

La Universidad del País Vasco, en colaboración con LKS NEXT¹, desarrolló el prototipo denominado I Need a Hero (INAH), diseñado para aprovechar el potencial de los LLM en la localización de expertos dentro de la organización[4]. INAH opera en dos fases: primero crea perfiles de “héroes” extrayendo información de currículos de empleados dispuestos a asistir; luego, ante una consulta, utiliza GPT-3.5 para identificar las competencias requeridas y localizar a los profesionales que las poseen.

En una línea de estudio complementaria, un trabajo reciente ha presentado el sistema “Onboarding Buddy”, el cual implementa una arquitectura multi-agente que organiza diversos componentes especializados para proporcionar asistencia contextualizada durante la incorporación de nuevos desarrolladores[5].

El sistema fundamenta su funcionamiento en la generación dinámica de planes mediante cadena de pensamiento 2.4.2, evaluados posteriormente para determinar su posible descomposición en sub-tareas procesadas en paralelo por otros agentes.

2.2. Agentes de Grandes Modelos de Lenguaje (LLM)

Los agentes de Inteligencia Artificial son programas informáticos que implementan modelos computacionales para ejecutar diversas funciones específicas del contexto en el que se aplican. Tras siete décadas y media de investigación, los esfuerzos en el campo se han focalizado en agentes basados en grandes modelos de lenguaje.

2.2.1. Modelos LLM

Los Grandes Modelos de Lenguaje son redes neuronales especializadas en el procesamiento del lenguaje natural que funcionan mediante un mecanismo de entrada-salida de tokens 2.2.1. Estos modelos reciben secuencias de tokens como entrada, denominada comúnmente “prompt”, y generan secuencias de tokens como salida, aplicando durante este proceso las representaciones y relaciones semánticas aprendidas durante su fase de entrenamiento con extensos corpus textuales [6].

Para comprender el funcionamiento de estos agentes, resulta imprescindible asimilar previamente conceptos como la tokenización, las representaciones vectoriales del lenguaje y el ajuste de dichos modelos.

¹LKS NEXT: <https://www.lksnext.com/es/>

Tokens Los tokens constituyen la unidad mínima de texto que el modelo puede procesar. Dado que dichos modelos operan sobre estructuras matemáticas, requieren transformar el lenguaje natural en representaciones matriciales. Para lograr esta conversión, el texto se segmenta en dichas unidades mínimas, que pueden corresponder a caracteres individuales, fragmentos de texto o palabras completas. El conjunto íntegro de estas unidades reconocibles por el modelo configura su vocabulario.

Representaciones vectoriales Constituyen vectores numéricos de dimensionalidad fija que codifican la semántica inherente a cada token. Por ejemplo, una dimensión específica podría especializarse en representar conceptos abstractos. En este contexto, la representación vectorial del token “animal” contendría un valor más elevado en dicha dimensión que la correspondiente al término “gato”, reflejando su mayor grado de abstracción conceptual.

Ajuste de modelos instruct El entrenamiento A.2 de los LLM se estructura en dos fases diferenciadas. La primera corresponde al preentrenamiento, donde el modelo procesa extensos conjunto de datos textuales con operaciones como intentar predecir el siguiente token en la secuencia. Esta fase permite al modelo captar las complejas estructuras sintácticas y relaciones semánticas inherentes al lenguaje natural. La segunda fase consiste en el ajuste fino, donde el modelo previamente entrenado se especializa mediante conjuntos de datos específicos y etiquetados A.1, optimizando su capacidad para ejecutar tareas concretas de clasificación o generación de texto.

Los agentes basados en LLM implementan en su mayoría modelos *instruct*, variantes especialmente ajustadas para responder a consultas e instrucciones de usuarios. Dentro de esta categoría se encuentran GPT (base de ChatGPT²) de OpenAI³, Claude Sonnet de Anthropic⁴, y Llama-Instruct de Meta⁵.

2.2.2. Interacción con herramientas externas

Los agentes LLM poseen la capacidad de interactuar con diversas herramientas como búsquedas web, bases de datos o interfaces de usuario. Fundamentalmente, este tipo de modelos solo genera tokens de texto, por lo que la integración de herramientas se implementa mediante palabras clave o tokens especiales que este puede incluir en su salida. Para ello, en el texto de entrada se especifica el esquema de la función a utilizar y, si decide emplearla, el modelo generará el texto correspondiente. Posteriormente, se procesa la respuesta para extraer llamadas a funciones si las hubiese.

La interacción con herramientas es típicamente alternante. Tras realizar la llamada a la herramienta, la salida de esta se utilizará como entrada para el siguiente mensaje del modelo. La Figura 2.1 ilustra el esquema de un agente con acceso a una API del clima. Como el modelo carece

²ChatGPT:<https://chatgpt.com>

³OpenAI:<https://openai.com/>

⁴Anthropic:<https://www.anthropic.com/>

⁵Meta: <https://about.meta.com/es/>

de información climática en tiempo real, se le indica en el prompt la posibilidad de invocar esta función. Al incluir la llamada en su texto de salida, se ejecuta la función y su respuesta se transmite al modelo para generar el resultado final.




Figura 2.1: Ejemplo de interacción de un modelo LLM con una herramienta externa.

2.2.2.1. Patrón ReAct

El agente Reasoning and Act (ReAct) constituye uno de los patrones más utilizados[7]. Se basa en un ciclo de tres pasos fundamentales: el razonamiento como generación de pensamiento sobre posibles acciones, la acción como ejecución de la herramienta seleccionada y la observación como procesamiento del resultado obtenido. Este ciclo se repite iterativamente hasta que durante la fase de razonamiento se determina que la tarea ha sido completada.

2.2.3. Abstracciones en frameworks

En pleno auge de los agentes LLM, surgen cada vez más bibliotecas y frameworks que estandarizan su implementación. Estos marcos de trabajo ofrecen abstracciones de alto nivel para reutilizar funcionalidades comunes presentes en la mayoría de sistemas de agentes. Las principales funcionalidades proporcionadas son las siguientes:

- **Gestión de modelos:** la ejecución de modelos de lenguaje requiere del dominio de estos, ya que cada uno posee tokenizadores específicos A.4 y esquemas propios de entrada y salida. Los frameworks ofrecen interfaces unificadas, facilitando el uso de diversos modelos sin necesidad de conocimientos técnicos excesivamente detallados.
- **Interacción conversacional:** la comunicación con los agentes se efectúa mediante un esquema conversacional, donde el modelo recibe un texto de entrada y genera una respuesta correspondiente. Las respuestas y entradas se concatenan secuencialmente para preservar el contexto de la conversación, cada consulta subsiguiente incorpora todos los intercambios precedentes.

- **Uso de herramientas externas:** toda la complejidad de la interacción se abstrae en el framework, por lo que el desarrollador únicamente debe especificar la función que desea incorporar.
- **Interacción entre agentes:** los agentes pueden establecer comunicación entre sí, permitiendo la construcción de sistemas con mayor complejidad. Algunos frameworks establecen protocolos que definen las modalidades de comunicación entre los distintos agentes.

Para este trabajo utilizaremos fundamentalmente LangChain⁶ para la gestión de llamadas a APIs de modelos y prompting, LangGraph⁷ para la orquestación de flujos agénticos, y LangSmith⁸ para el seguimiento de trazas de llamadas a modelos y herramientas. Para la gestión de los conjuntos de datos y entrenamiento de modelos utilizaremos HuggingFace.⁹

2.3. Model Context Protocol

El Model Context Protocol (MCP), desarrollado por Anthropic, estandariza la comunicación entre agentes LLM y herramientas. Permite que aplicaciones diversas ofrezcan herramientas a agentes externos sin exponer detalles de implementación[8].

La Figura 2.2 ilustra el esquema operativo del protocolo. Los desarrolladores de Jira¹⁰ y GitHub¹¹ han implementado un servidor MCP que traduce las interacciones con sus APIs y proporciona herramientas al cliente MCP. Esto permite que el desarrollador del agente se enfoque exclusivamente en conectar las herramientas del cliente con el agente, sin necesidad de interactuar con APIs externas. Asimismo, el cliente MCP gestiona la comunicación entre servidores, facilitando al agente el acceso directo a múltiples herramientas.

⁶LangChain: <https://www.langchain.com/>

⁷LangGraph: <https://www.langchain.com/langgraph>

⁸LangSmith: <https://www.langchain.com/langsmith>

⁹HuggingFace: <https://huggingface.co/>

¹⁰Jira: <https://www.atlassian.com/es/software/jira>

¹¹GitHub: <https://github.com/>




Figura 2.2: Esquema de funcionamiento del Model Context Protocol.

El protocolo ofrece dos modos de operación para establecer la comunicación entre cliente y servidor:

- **Comunicación SSE:** el protocolo Server-Sent Events (SSE) establece un canal de comunicación unidireccional sobre HTTP desde el servidor hacia el cliente. Proporciona actualizaciones en tiempo real con capacidad de streaming. En el protocolo MCP, el cliente efectúa solicitudes para la ejecución de herramientas en el servidor mediante HTTP, a lo que el servidor puede responder mediante eventos SSE.
- **Comunicación STDIO:** el protocolo de entrada y salida estándar (STDIO) facilita la comunicación bidireccional entre cliente y servidor a nivel de proceso en el sistema operativo. Este mecanismo permite el intercambio de información en formato JSON a través de los canales estándar del sistema. Su diseño, orientado principalmente a entornos locales, restringe la conexión a un único cliente por servidor al limitarse a la comunicación entre dos procesos.

La aplicación de escritorio Claude Desktop¹² de Anthropic constituye un reflejo del potencial del protocolo. Esta plataforma ofrece la posibilidad de interactuar con servidores mediante una configuración mínima. Implementando el protocolo STDIO, la aplicación ejecuta los servidores distribuidos por terceros a través de gestores de paquetes como uv¹³, npx¹⁴ o Docker¹⁵. Al incorporar un cliente MCP en la aplicación, consigue integrar las herramientas disponibles en la interfaz de chat con los modelos de Anthropic.

¹²Claude Desktop: <https://claude.ai/download>

¹³uv: <https://astral.sh/blog/uv>

¹⁴npx: <https://docs.npmjs.com/cli/v8/commands/npx>

¹⁵Docker: <https://www.docker.com/>

2.4. Estado del arte en arquitecturas de agentes LLM

La comunidad científica ha diseñado diversas arquitecturas de agentes para optimizar el rendimiento de los modelos disponibles. La arquitectura RAG se distingue por complementar la entrada del modelo con información recuperada de documentos relevantes. Otras propuestas se centran en mejorar la comunicación y coordinación entre agentes.

2.4.1. Arquitectura RAG

Los modelos LLM poseen un conocimiento restringido a los datos con los que fueron entrenados. Para superar esta limitación, la arquitectura RAG (Retrieval-Augmented Generation) complementa la generación del LLM mediante la recuperación de información relevante desde repositorios de conocimiento externos. La Figura 2.3 ilustra un ejemplo de su funcionamiento.

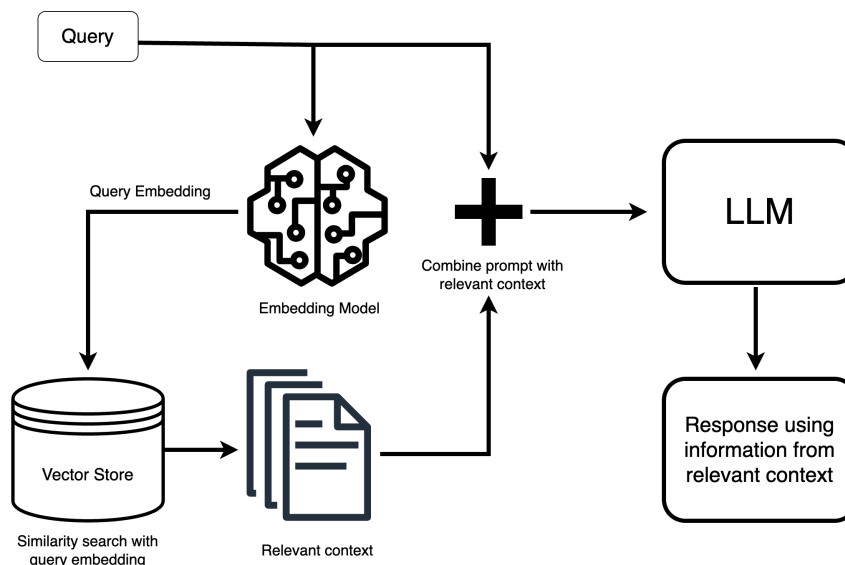


Figura 2.3: Esquema de funcionamiento de la arquitectura RAG en un LLM [Fuente](#).

La recuperación de documentos relevantes se puede implementar mediante recuperadores dispersos: expresiones regulares, búsqueda de n-gramas, palabras clave, entre otras. No obstante, el enfoque predominante consiste en el uso de recuperadores densos, conocidos como indexación vectorial. En este método, los documentos se transforman en vectores, generalmente mediante LLMs especializados en codificación, denominados Embedders. Al representar los documentos en un espacio vectorial, es posible recuperar aquellos semánticamente más pertinentes mediante la comparación del vector de consulta con los vectores de los documentos indexados, utilizando métricas como la distancia coseno [A.3](#).

2.4.1.1. Estrategias RAG avanzadas

La optimización del rendimiento en arquitecturas RAG ha sido ampliamente estudiada [9][10], enfocándose en tres áreas principales: el procesamiento de documentos, los sistemas de recuperación y la mejora del flujo de generación.

- **Procesado de documentos:** la calidad de la indexación documental determina la eficacia del sistema. Entre las estrategias destacadas figuran la eliminación de ruido textual, el ajuste del tamaño óptimo de los segmentos indexados, y la técnica de ventana solapada. Esta última superpone fragmentos para preservar los datos situados en las intersecciones de los segmentos.
- **Sistemas de recuperación:** los recuperadores densos basados en representaciones, ilustrados en la Figura 2.3, precálculan las representaciones vectoriales de los documentos mediante una indexación independiente de las consultas. Por otro lado, los recuperadores basados en interacción, proponen calcular el vector para cada documento junto al vector de consulta durante el tiempo de ejecución, obteniendo así una representación más rica que captura las relaciones contextuales específicas entre ambos elementos[11][12].

Para contrarrestar el sobrecoste computacional de este enfoque, se han desarrollado técnicas de indexación híbridas que combinan ambos métodos. Estas técnicas permiten realizar una búsqueda inicial utilizando representaciones vectoriales y posteriormente refinar los resultados mediante la extracción interactiva[13].

- **Optimización del flujo de generación:** para tareas que requieren reflexión documentada, se han desarrollado sistemas de salto múltiple que alternan entre recuperación y generación[14][15][16][17][18]. Estos flujos permiten al sistema examinar críticamente la información inicialmente recuperada, identificar lagunas informativas, y formular las consultas correspondientes para subsanar dichas carencias.

2.4.2. Arquitecturas de interacción entre agentes

La interacción entre agentes LLM constituye un campo de investigación activo, distinguiéndose diversos avances en módulos de memoria, planificación e interacción multiagente[19].

- **Módulos de memoria:** en una interacción conversacional, el modelo procesa todos los mensajes previos, pudiendo generar un contexto excesivamente amplio. Para mitigar este problema, se han desarrollados módulos de memoria que almacenan información relevante de interacciones pasadas de forma resumida[20][21][22]. Esta memoria puede consultarse posteriormente mediante RAG, permitiendo recuperar los elementos más relevantes según el contexto[23].

Algunos módulos se inspiran en la estructura de la memoria humana[24], incorporando mecanismos que almacenan información con distintas temporalidades y niveles de relevancia[19][25].

- **Planificación:** los mecanismos de planificación potencian el razonamiento de los agentes sobre sus acciones futuras.

Entre estos mecanismos destaca el prompting de cadena de pensamiento (Chain of Thought)[26], que instruye al modelo para elaborar un razonamiento secuencial previo a su decisión final, permitiendo así descomponer problemas complejos paso a paso. Partiendo de este enfoque, estrategias avanzadas como la autoconsciencia[22] lo amplían mediante la generación de múltiples cadenas de razonamiento independientes y la posterior selección de la respuesta óptima entre ellas[27][28].

De manera complementaria, las técnicas de reflexión[29][30][31] implementan un proceso iterativo donde el propio modelo evalúa y refina sus respuestas.

Por otro lado, la estructuración de acciones constituye una metodología ampliamente adoptada en la planificación[32][33][34]. Esta técnica permite definir planes de alto nivel que posteriormente se desglosan en acciones específicas ejecutables por los agentes[35][36][37][38]. Adicionalmente, la definición de interdependencias entre estas acciones permite verificar la validez de los planes generados[39][40][41].

Los modelos razonadores como o1 de OpenAI o DeepSeek-R1 incorporan estas técnicas de forma nativa[42]. Estos han sido entrenados con datos que incluye ejemplos de razonamiento y planificación, lo que les permite generar respuestas que incluyen dichas estructuras.

- **Interacción entre agentes:** los sistemas multi-agente implementan una arquitectura donde diversos agentes especializados son coordinados por un componente central denominado orquestador[43][44]. En este paradigma, cada agente se especializa en una función particular, como la búsqueda de información, la ejecución de herramientas o la generación de texto. El orquestador evalúa las consultas entrantes y las dirige hacia el agente más competente para resolverlas.

Enfoques complementarios proponen la interacción directa entre agentes especializados como mecanismo de retroalimentación[45][46]. Por ejemplo, ChatDev[47] establece un sistema de colaboración entre agentes programadores, testers y gestores para abordar problemas de ingeniería de software. MetaGPT[48] refina esta propuesta al implementar un protocolo de comunicación basado en el patrón publicador/suscriptor entre los agentes, permitiéndoles difundir información de forma selectiva.

2.5. Agentes LLM en proyectos software

La integración de agentes en proyectos software ha sido objeto de estudio enfocándose principalmente en el ámbito de la generación automática de código. Se pueden destacar tres niveles

de autonomía en los productos desarrollados: sugerencias de autocompletado, asistentes de programación y agentes autónomos.

- **Sugerencias de autocompletado:** GitHub Copilot¹⁶ o Cursor¹⁷ ofrecen la integración de un modelo LLM ajustado para generación de código directamente al entorno del desarrollador. De esta forma, el desarrollador recibe sugerencias de autocompletado en tiempo real mientras escribe el código.

Este tipo de herramientas han demostrado ser eficaces para aumentar la productividad de los desarrolladores en tareas de programación repetitivas[49]. Sin embargo, debido a su enfoque en la rapidez de respuesta, presentan limitaciones en la aplicación de razonamiento profundo.

- **Asistentes de programación:** principalmente en aplicaciones en forma de chat, herramientas como GitHub Copilot Chat, Cursor o Cody¹⁸ de SourceGraph¹⁹ ofrecen un sistema de chat interactivo que permite al desarrollador realizar preguntas específicas sobre el código[50].

Cabe destacar el proyecto SourceGraph, el cual al ser inicialmente de código abierto ha publicado una explicación de su funcionamiento. Proporciona un sistema avanzado de navegación de código que permite la integración del agente LLM denominado Cody.

La arquitectura de este sistema opera en dos etapas: en primera instancia, los servidores de lenguaje específicos para cada lenguaje de programación analizan la estructura del código fuente, generando un grafo de dependencias que representa las relaciones jerárquicas entre los distintos elementos del código (funciones, clases, métodos, interfaces, entre otros)[51]. Posteriormente, el sistema implementa un mecanismo RAG basado en trigramas sobre el grafo del proyecto, cuyos fragmentos son suministrados al agente Cody, que procesa esta información estructurada y elabora respuestas contextualizadas a las consultas del desarrollador[52].

- **Agentes autónomos:** con un enfoque más ambicioso, soluciones como Aider²⁰ o DevinAI²¹ persiguen la automatización del ciclo completo de desarrollo de software. Debido a la complejidad inherente a dicha tarea, estas herramientas permanecen en una fase incipiente[53].

El funcionamiento de Aider presenta similitudes con SourceGraph[54]. En primera instancia, analiza el código fuente mediante la biblioteca Tree-sitter²², generando un grafo de dependencias que representa las definiciones (funciones, clases, interfaces, etc.) y las referencias

¹⁶GitHub Copilot: <https://github.com/features/copilot>

¹⁷Cursor: <https://www.cursor.com/>

¹⁸Cody: <https://sourcegraph.com/cody>

¹⁹SourceGraph: <https://sourcegraph.com/>

²⁰Aider: <https://aider.chat/>

²¹DevinAI: <https://devin.ai/>

²²Tree-sitter: <https://tree-sitter.github.io/tree-sitter/>

entre estas. Posteriormente, implementa un algoritmo de clasificación de grafos para determinar la relevancia de cada nodo respecto al contexto actual. De este modo, incorpora dicho contexto junto con un mapa de los ficheros del proyecto en la entrada del agente LLM.

2.6. Ajuste de modelos para agentes LLM

2.6.1. Limitaciones de los modelos actuales

Los modelos *instruct* del estado del arte poseen la capacidad de resolver tareas que requieren comportamiento agéntico gracias a su amplio conocimiento general. No obstante, su eficiencia es cuestionable, puesto que para tareas específicas pueden carecer de ciertos conocimientos particulares, mientras que disponen de una cantidad considerable de información superflua. Se estima que los modelos más avanzados en la actualidad, como GPT-4o o Claude 3.7 Sonnet, contienen cientos de miles de millones de parámetros[55], lo que los convierte en prohibitivamente costosos para su ejecución en entornos locales.

Debido a estas limitaciones y por tratarse de modelos propietarios, estos están disponibles únicamente a través de API. Este modelo de acceso requiere enviar los datos a servidores externos, planteando así preocupaciones sobre la privacidad y la seguridad de la información. Esta restricción es especialmente relevante en el ámbito del desarrollo de software, donde los datos pueden incluir información sensible o confidencial.

2.6.2. Enfoques de ajuste fino para agentes específicos

Como consecuencia de estas limitación, diversos proyectos de investigación han propuesto el ajuste fino de modelos de menor dimensión para tareas agénticas específicas. Mediante esta aproximación, es posible obtener modelos con mayor precisión en las tareas requeridas, pero con una fracción del coste.

Enfoques como FireAct[56] y AgentTuning[57] proponen el entrenamiento de dichos modelos mediante una estrategia de destilación. Esto consiste en previamente utilizar un modelo *instruct* de gran tamaño para generar un conjunto de datos sintéticos para las respuestas del agente. Posteriormente, se ajusta un modelo de menor tamaño utilizando este conjunto de datos, de forma que el conocimiento del modelo grande se destila en el modelo pequeño.

Adicionalmente, Agent-FLAN[58] propone la división de dichos datos de entrenamiento en varios conjuntos de aprendizaje. Debido a que los modelos aprenden antes a interpretar el formato de entrada que a razonar sobre la acción a realizar, se propone modificar parte de las trazas de entrenamiento para que estas tengan una estructura conversacional. De esta forma, al ajustar el modelo con las trazas originales, este aprende la estructura de entrada y llamada de herramientas, mientras que en las trazas conversacionales, el modelo aprende a razonar sobre la acción a realizar.

2.6.3. Técnicas de entrenamiento eficiente

El entrenamiento de estos modelos se realiza mediante el ajuste de los pesos de la red neuronal. Debido a que el ajuste fino del modelo completo es costoso, en contextos de bajo coste se propone el uso de la técnica de entrenamiento Low Rank Adaptation (LoRA)[\[59\]](#). Esta técnica consiste en ajustar únicamente un subconjunto de los pesos de la red neuronal, lo que permite reducir significativamente el coste computacional del ajuste fino.

Planificación

En este capítulo se presenta la planificación del proyecto, abordando el alcance definido, los periodos de realización de tareas y los diversos ámbitos de gestión: temporal, de riesgos, de comunicaciones e información, y de partes interesadas. El objetivo de esta planificación es establecer una hoja de ruta estructurada que permita el cumplimiento de todos los objetivos del proyecto dentro de los plazos establecidos.

3.1. Alcance

Este proyecto aborda el desarrollo de un sistema basado en agentes LLM implementado sobre una solución software propia de LKS NEXT, con el propósito de investigar el comportamiento de diversas arquitecturas de agentes definidas en el Capítulo 2 y evaluar su viabilidad para su futura incorporación en los procesos productivos de la empresa.

En dicho sistema, se implementarán diversas modalidades de interacción entre agentes especializados en fuentes de datos específicas, evaluando la eficacia de los distintos patrones de comunicación entre dichos componentes.

Cabe destacar que el alcance del proyecto no está definido en su totalidad, dada la complejidad de estimación inherente a su naturaleza exploratoria y al uso de tecnologías emergentes. Para mitigar riesgos en el desarrollo, se ha establecido un protocolo preventivo que contempla reuniones quincenales de seguimiento y control.

3.1.1. Objetivos concretos del proyecto

Para facilitar el logro del objetivo principal, se han identificado y definido los siguientes objetivos específicos que estructuran el avance progresivo del proyecto:

- **Estudio de arquitecturas agénticas:** realizar un análisis de las diversas arquitecturas de agentes, considerando distintas estrategias de interacción y mecanismos de acceso a fuentes de información.
- **Desarrollo de sistema de Onboarding:** implementar las arquitecturas propuestas en un proyecto software corporativo, con el propósito de analizar su eficacia en la asistencia a nuevos integrantes durante su proceso de incorporación a la empresa.
- **Integración del Model Context Protocol:** exploración de las características y beneficios que aporta la implementación del protocolo MCP, con el objetivo de realizar una valoración objetiva para su posible integración en el entorno profesional de la empresa.
- **Evaluación de agentes:** desarrollar un sistema de evaluación para proporcionar métricas comparativas cuantificables sobre el rendimiento de los diferentes enfoques de agentes.
- **Valoración de ajuste de agentes:** analizar la relación coste-beneficio asociada al proceso de ajuste fino de modelos LLM para su aplicación en agentes concretos.

Adicionalmente, el proyecto contempla desarrollar el sistema de onboarding incorporando en la medida de lo posible en su base de conocimiento la metodología de trabajo implementada en la empresa. Mediante la adhesión a los estándares definidos en un entorno profesional real, se pretende garantizar que los resultados obtenidos constituyan un reflejo de la viabilidad de implementación y eficacia de proyectos similares en un sistema de explotación.

3.1.2. Requisitos

Los requisitos del proyecto se detallan en profundidad en la Sección [4](#)

3.1.3. Fases del proyecto

Tal y como se ha mencionado anteriormente, el alcance del proyecto no está completamente definido debido a su naturaleza exploratoria. Consecuentemente, se propone un ciclo de vida iterativo-incremental con iteraciones de aproximadamente dos semanas de duración, permitiendo una adaptación progresiva a los requisitos emergentes.

La primera iteración se centra en la captura de requisitos del proyecto, donde se explorará y definirá el alcance del sistema de agentes a desarrollar. Tras establecer estas bases, la segunda iteración abordará la implementación de un sistema de agentes mínimo que contenga la estructura general del sistema, proporcionando un marco operativo inicial.

Con este sistema mínimo implementado, la tercera iteración corresponderá al desarrollo de un mecanismo de evaluación, con el objetivo de establecer métricas que permitan mejorar el sistema en la cuarta iteración, donde se aplicarán las optimizaciones identificadas. La quinta iteración se

dedicará a la implementación de arquitecturas de agentes exploratorias, evaluando su rendimiento mediante las métricas previamente establecidas.

Finalmente, la sexta iteración contemplará el ajuste fino de un modelo LLM para su integración en un agente específico del sistema, así como su evaluación contextualizada dentro del entorno funcional del proyecto.

Gracias a la implementación del ciclo de vida iterativo, se logra la consecución de los objetivos del proyecto de forma progresiva y estructurada. Este enfoque permite obtener retroalimentación constante por parte de los directores del proyecto durante cada iteración, facilitando así la posibilidad de reorientar la dirección del trabajo ante la aparición de posibles contratiempos.

3.1.4. Descomposición de tareas

La Estructura de Descomposición de Trabajo (EDT) del proyecto se ha creado considerando el ciclo de vida iterativo-incremental del proyecto. La Figura 3.1 ilustra un diagrama de esta.

Se divide en los siguientes paquetes:

■ **1ª iteración:**

- **Captura de requisitos (CR):** actividades orientadas a la definición de los requisitos necesarios para el desarrollo del proyecto.
 - **Definición de requisitos principales:** identificación y documentación de los requisitos del proyecto, validados con los directores al inicio del mismo.
 - **Elicitación de requisitos:** recopilación de preguntas potenciales para el sistema desarrollado mediante cuestionario electrónico y análisis posterior de las respuestas.
- **Recopilación de recursos disponibles (RR):** actividades centradas en la selección y generación de recursos esenciales para el desarrollo.
 - **Selección de proyecto software:** identificación y documentación del proyecto software sobre el que se desarrollará el sistema.
 - **Generación de recursos:** elaboración de documentación complementaria para la implementación del sistema de agentes.
- **Definición del alcance del sistema de agentes (DA):** delimitación del alcance considerando implementaciones previas y trabajo académico existente.
 - **Investigación de arquitecturas del estado del arte:** análisis de las arquitecturas relevantes documentadas en la literatura académica.
 - **Exploración de proyectos similares:** estudio de implementaciones similares en proyectos software y procesos de Onboarding.

■ **2ª iteración:**

- **Sistema de agentes (SA):** actividades centradas en el diseño e implementación de un sistema de agentes LLM para asistencia en proyectos software.
 - **Diseño del sistema:** conceptualización e implementación básica de los módulos fundamentales del sistema.
 - **Implementación de agentes especializados:** desarrollo de agentes adaptados a las diversas fuentes de información disponibles.
 - **Sistema de comunicación mínima:** creación de un mecanismo básico de orquestación para los agentes implementados.
- **Pruebas y evaluación (P):** actividades destinadas a verificar y analizar el rendimiento de los módulos implementados.
 - **Pruebas automatizadas:** desarrollo de pruebas unitarias para algoritmos críticos de los agentes especializados.
 - **Integración continua:** implementación de un flujo de trabajo automatizado para la ejecución de pruebas unitarias.
- **3ª iteración:**
 - **Sistema de agentes (SA):** actividades centradas en el diseño e implementación de un sistema de agentes LLM para asistencia en proyectos software.
 - **Sistema de evaluación:** implementación de mecanismos de evaluación automática sobre el sistema mínimo.
 - **Captura de datos de evaluación:** anotación manual de ejemplos representativos para evaluar el rendimiento del sistema.
 - **Pruebas y evaluación (P):** actividades destinadas a verificar y analizar el rendimiento de los módulos implementados.
 - **Evaluación del sistema mínimo:** ejecución de evaluaciones automatizadas e identificación de elementos clave para mejoras posteriores.
- **4ª iteración:**
 - **Sistema de agentes (SA):** actividades centradas en el diseño, implementación y evaluación de un sistema de agentes LLM para asistencia en proyectos software.
 - **Mejora de agentes:** refinamiento de los agentes implementados para optimizar su rendimiento según las métricas establecidas.
 - **Variaciones de orquestación:** análisis e implementación de estrategias alternativas de orquestación.
 - **Pruebas y evaluación (P):** actividades destinadas a verificar y analizar el rendimiento de los módulos implementados.

- **Evaluación comparativa:** ejecución de evaluaciones automatizadas y análisis comparativo respecto a la iteración anterior.

■ **5ª iteración:**

- **Sistema de agentes (SA):** actividades centradas en el diseño e implementación de un sistema de agentes LLM para asistencia en proyectos software.
 - **Arquitecturas de interacción alternativas:** implementación y evaluación de mecanismos adicionales de interacción entre agentes.
 - **Módulos de memoria:** integración de sistemas de memoria y evaluación de su impacto en el rendimiento global.
 - **Agentes avanzados:** desarrollo de un agente con un proceso de ejecución extenso para el análisis del coste-beneficio.
- **Pruebas y evaluación (P):** actividades destinadas a verificar y analizar el rendimiento de los módulos implementados.
 - **Evaluación comparativa:** análisis del rendimiento de las nuevas características respecto al sistema precedente.

■ **6ª iteración:**

- **Ajuste de modelo (AM):** actividades orientadas al entrenamiento especializado de un modelo para un agente específico.
 - **Selección del agente:** identificación justificada del agente candidato para el ajuste del modelo.
 - **Extracción de datos:** recopilación automatizada de datos de entrenamiento mediante un modelo de alto rendimiento.
 - **Entrenamiento del modelo:** diseño y ejecución del ciclo de entrenamiento del modelo LLM seleccionado.
- **Sistema de agentes (SA):** actividades centradas en el diseño e implementación de un sistema de agentes LLM para asistencia en proyectos software.
 - **Incorporación del modelo ajustado:** desarrollo de adaptadores e integración del modelo en el sistema existente.
- **Pruebas y evaluación (P):** actividades destinadas a verificar y analizar el rendimiento de los módulos implementados.
 - **Evaluación comparativa:** análisis del rendimiento del sistema con el modelo ajustado frente a versiones anteriores.

■ **Gestión (G):**

- **Planificación (PL):** establecimiento de directrices, objetivos y actividades para el desarrollo óptimo del proyecto.
 - **Seguimiento y control (SC):** monitorización periódica mediante reuniones bisemanales con los directores del proyecto.
- **Trabajo académico (TA):**
- **Memoria (M):** elaboración del documento académico que recoge todo el trabajo realizado.
 - **Defensa (D):** preparación de la presentación y defensa del proyecto ante el tribunal evaluador.

3.2. Periodos de realización de tareas e hitos

En este apartado se detallan las dependencias entre las diferentes tareas, así como la estimación de duración y fechas de cada una de ellas.

3.2.1. Dependencias entre tareas

Las dependencias de los paquetes de trabajo del proyecto requieren una ejecución secuencial planificada. La Figura 3.2 ilustra dichas dependencias.

El proyecto se inicia con una primera iteración centrada en la captura de requisitos, invirtiendo un tiempo significativo en alinear los objetivos con las necesidades empresariales. Esta fase comprende la captura de requisitos (CR), la recopilación de recursos disponibles (RR) y la definición del alcance y requisitos del sistema de agentes (DA).

Las iteraciones intermedias desarrollan progresivamente el paquete Sistema de agentes (SA) mediante fases complementarias. La segunda iteración implementa su diseño conceptual, agentes especializados y un sistema de comunicación mínima. Posteriormente, en la tercera iteración, el sistema evoluciona incorporando mecanismos de evaluación y captura de datos. La cuarta iteración optimiza los agentes existentes y explora variaciones en la orquestación, mientras que la quinta implementa arquitecturas de interacción alternativas, módulos de memoria y agentes de procesamiento avanzado.

La sexta iteración introduce el paquete Ajuste de modelo (AM), que comprende la selección del agente candidato, extracción de datos y entrenamiento especializado. Simultáneamente, el paquete SA aborda actividades de integración del modelo ajustado en la arquitectura existente.

Transversalmente, se establecen los paquetes de Gestión (G), que abarca actividades de planificación y seguimiento mediante reuniones bisemanales, y Trabajo académico (TA), orientado a la elaboración de la memoria y preparación de la defensa.

Cabe destacar que a partir de la segunda iteración, cada fase incorpora el paquete de Pruebas y evaluación (P), destinado a verificar y analizar el rendimiento de los módulos implementados. Este paquete evoluciona progresivamente desde pruebas automatizadas básicas hasta evaluaciones comparativas que contrastan el rendimiento entre iteraciones sucesivas.

3.2.2. Diagrama de Gantt

La Figura 3.3 muestra el diagrama de Gantt, donde se visualiza de manera aproximada la distribución temporal a cada paquete de trabajo durante el transcurso del proyecto. Los rombos negros señalan los hitos clave que se detallan en la Sección 3.2.3.

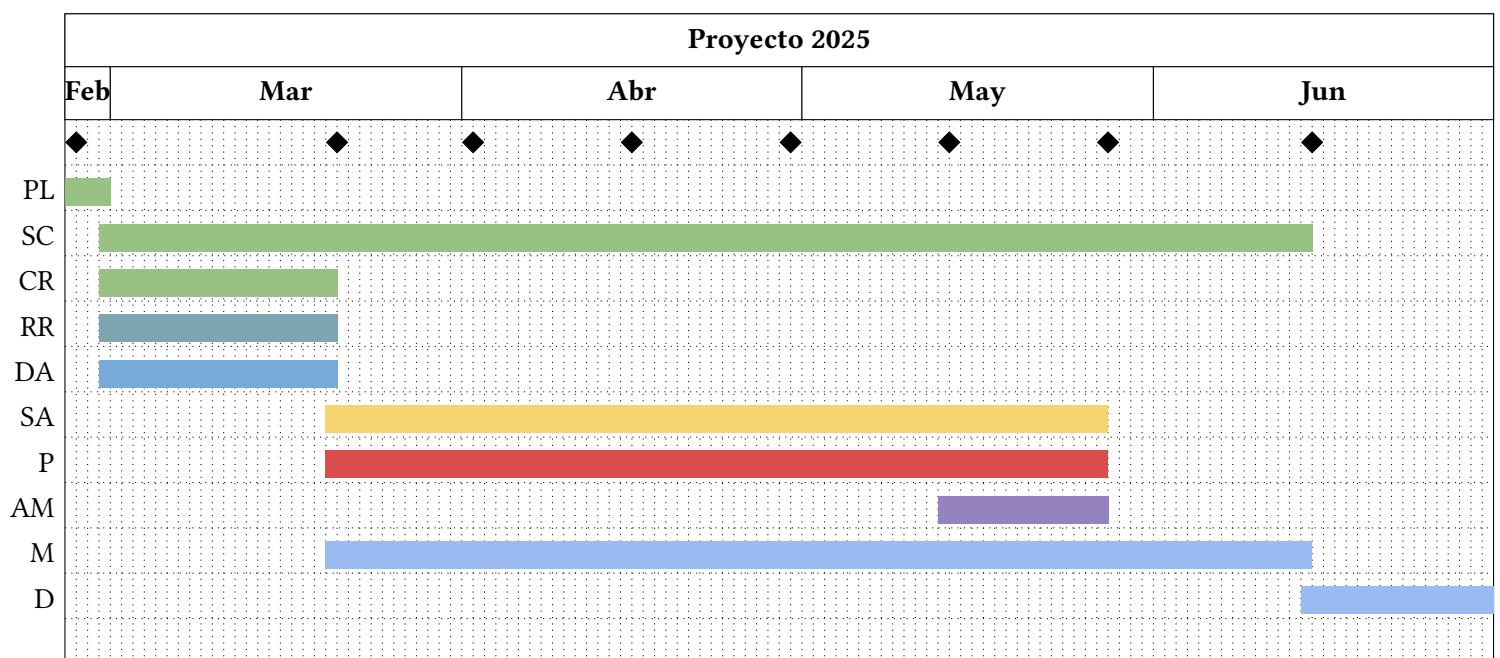


Figura 3.3: Diagrama de Gantt del proyecto

3.2.3. Hitos

En la Tabla 3.1 se detallan los hitos establecidos para el desarrollo del proyecto. La finalización de la fase de implementación ha sido programada para el 31 de mayo, tras lo cual se destinarán dos semanas íntegramente a la elaboración de la memoria hasta el 14 de junio, proporcionando así un margen de 8 días previos a la fecha límite de entrega. Este período de contingencia está planificado para abordar posibles contratiempos que pudieran surgir durante el transcurso del proyecto.

Hito	Fecha
Inicio del proyecto	25/02/2025
Fin Iteración 1	20/03/2025
Fin Iteración 2	01/04/2025
Fin Iteración 3	15/04/2025
Fin Iteración 4	29/04/2025
Fin Iteración 5	13/05/2025
Fin Iteración 6	27/05/2025
Fin memoria	14/06/2025
Defensa del proyecto	Por determinar

Tabla 3.1: Cronograma de Hitos del Proyecto

3.3. Gestión del tiempo

Se ha gestionado el tiempo disponible para el proyecto considerando el alcance definido para cumplir todos los objetivos del proyecto.

3.3.1. Estimación de cada tarea

La estimación específica de cada tarea se puede ver en la [Tabla 3.4](#)

3.4. Gestión de riesgos

Debido al enfoque exploratorio del proyecto, la gestión de riesgos cobra especial importancia. Se han identificado los siguientes riesgos con su correspondiente plan de contingencia:

- **R1- Concurrencia exploratoria:** dado que el proyecto está enfocado en tecnologías emergentes, existe la posibilidad de que durante el período de desarrollo emerjan iniciativas paralelas que aborden la misma problemática.

Para abordar este riesgo, se realizará una previa investigación de soluciones existentes antes de implementar cada módulo del sistema, así como un análisis periódico que permita identificar mejoras inspiradas en avances externos.

- **R2- Variabilidad del alcance:** al ser un proyecto exploratorio, con un alcance inicialmente ambiguo, podría sufrir alteraciones no planificadas. Estos contratiempos podrían suponer un sobrecoste horario, lo que obligaría a replanificar el alcance para no sobrepasar ampliamente los recursos disponibles.

Para mitigar este riesgo, se implementará un seguimiento y control mediante reuniones quincenales que permitirán evaluar la correcta evolución de las actividades y, en caso

necesario, adoptar medidas correctivas para garantizar la viabilidad del trabajo dentro de los plazos establecidos.

- **R3- Dependencia de sistemas externos:** la implementación del proyecto depende significativamente de sistemas externos, tanto por los modelos de lenguaje accedidos a través de APIs como por los servicios proporcionados por los servidores MCP. Cualquier alteración o interrupción en estos servicios podría comprometer la funcionalidad del sistema implementado.

Para prevenir este riesgo, se diseñará un sistema con un manejo de excepciones robusto que garantice la continuidad operativa incluso cuando alguno de los módulos experimente fallos. Complementariamente, se adoptará una arquitectura de desarrollo modular que facilite la integración o desacoplamiento de componentes según las necesidades evolutivas del proyecto.

- **R4- Filtrado de credenciales:** el acceso a recursos externos sobre el que se desarrolla el proyecto requiere de claves secretas. Es necesario considerar que existen algoritmos de rastreo automatizados que analizan plataformas públicas en busca de credenciales expuestas para su uso fraudulento. La publicación inadvertida de estas claves en entornos públicos podría ocasionar pérdidas económicas considerables o comprometer la seguridad del sistema corporativo.

Para contrarrestar este riesgo, se implementará una política de gestión de credenciales mediante variables de entorno, evitando su inclusión directa en el código fuente o su transferencia a plataformas en la nube. Adicionalmente, se mantendrán todos los repositorios y sistemas posibles en modo de visibilidad privada.

- **R5- Pérdida de recursos:** el desarrollo del proyecto se fundamenta en múltiples recursos esenciales, incluyendo el código fuente del sistema, la documentación de requisitos, los diversos artefactos generados durante el proceso de desarrollo y la propia memoria académica. La pérdida de cualquiera de estos elementos debido a fallos técnicos o incidentes fortuitos podría ocasionar un retraso significativo.

Para mitigar este riesgo, se han implementado los sistemas de información descritos en la Sección 3.5.1 que garantizan el mantenimiento de copias de seguridad actualizadas diariamente en la nube. Mediante esta estrategia preventiva, cualquier eventualidad que afecte al dispositivo principal de desarrollo supondría, como máximo, la pérdida del trabajo correspondiente a una jornada.

3.5. Gestión de Comunicaciones e Información

3.5.1. Sistema de información

La gestión de la información del proyecto se ha estructurado mediante los siguientes sistemas tecnológicos:

- **Repositorio GitHub para código fuente:** el código desarrollado será alojado en un repositorio privado de GitHub.
- **Repositorio GitHub para documentación:** la memoria del proyecto, elaborada utilizando LaTeX en el entorno local del alumno, será sincronizada con un repositorio dedicado en GitHub.
- **Almacenamiento en Google Drive¹:** los diversos recursos y materiales auxiliares recopilados durante las fases de desarrollo serán almacenados en esta plataforma.

Esta estructura de gestión de la información aporta diversos beneficios al proyecto. Por un lado, facilita la supervisión continua por parte de los directores e implementa un control de versiones organizado que documenta la evolución del trabajo. Por otro lado, garantiza copias de seguridad actualizadas que protegen la integridad de los datos. Adicionalmente, asegura la accesibilidad para todos los interesados.

3.5.2. Sistema de comunicación

La comunicación eficaz entre alumno, director empresarial y directores académicos resulta imprescindible para el correcto seguimiento y control del proyecto. Las herramientas a utilizar son:

- **Correo electrónico:** canal principal para consultas con los directores del proyecto y comunicación formal con otros miembros de la empresa.
- **Google Meet:** plataforma destinada a la realización de reuniones telemáticas entre los participantes.
- **Google Chat:** herramienta complementaria para resolución de consultas rápidas con el director empresarial.

3.6. Herramientas disponibles

Para el desarrollo del proyecto se dispone de varias herramientas que facilitan su implementación y gestión eficiente:

¹Google Drive: <https://workspace.google.com/intl/es/products/drive/>

- **IDE PyCharm²**: se usará la versión Professional del entorno de desarrollo PyCharm, obtenida a través del paquete educativo de GitHub, que proporciona herramientas especializadas para el desarrollo en Python.
- **Asistencia de herramientas de inteligencia artificial**: se dispone de herramientas de asistencia basadas en inteligencia artificial como GitHub Copilot y una suscripción al modelo Claude, que optimizan las tareas de programación, el procesamiento documental y la redacción de la presente memoria.
- **Claves de acceso a modelos**: la empresa LKS NEXT ha facilitado las credenciales de acceso necesarias para la integración y ejecución de los diferentes modelos LLM utilizados en el proyecto.
- **Plataformas de computación en la nube**: se dispone de acceso a infraestructuras de computación en la nube con unidades de procesamiento gráfico (GPU) dedicadas para el entrenamiento e inferencia del modelo ajustado.

²PyCharm: <https://www.jetbrains.com/es-es/pycharm/>

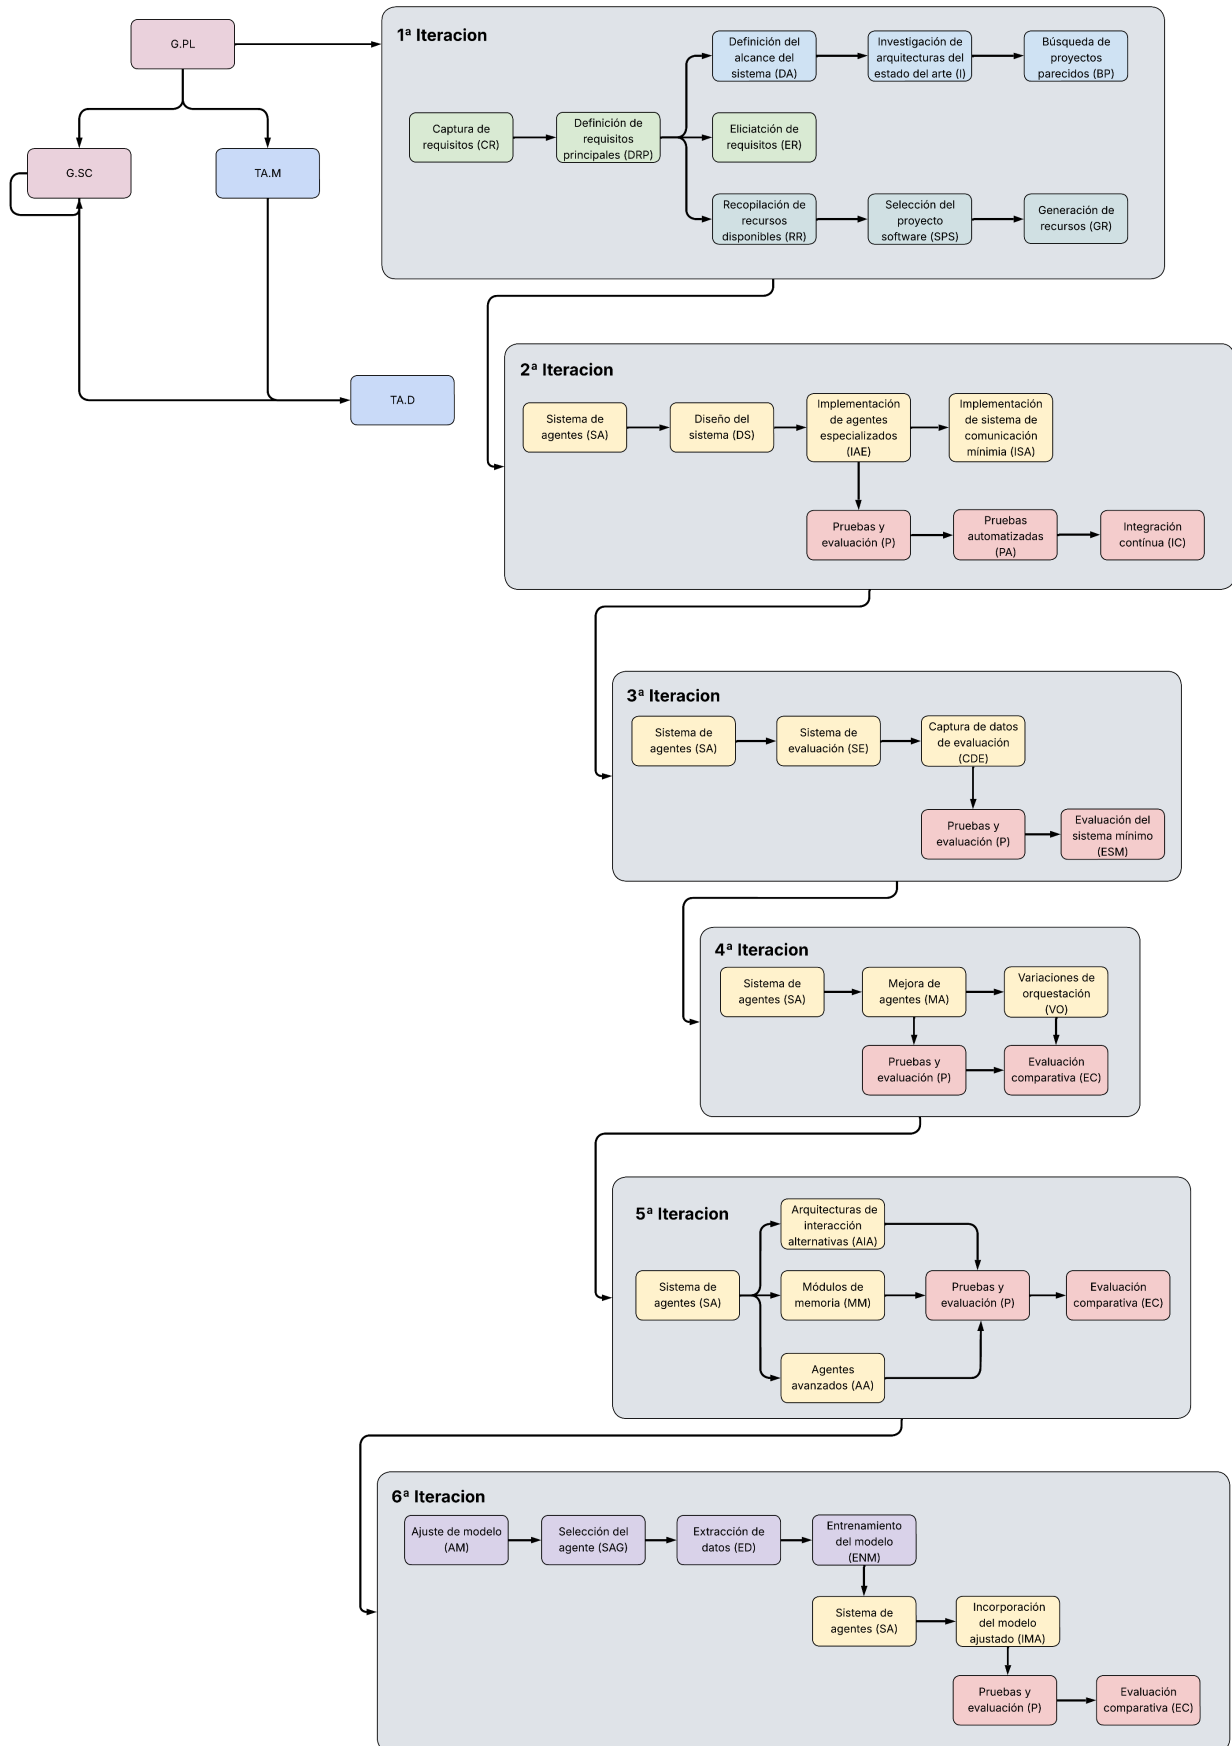



Figura 3.2: Dependencias entre tareas del proyecto

Iteración	Paquete de trabajo	Tarea	Dedicación estimada (H)	Horas totales
1ª Iteración	Captura de requisitos(CR)	Definición de requisitos principales	7	361
		Elicitación de requisitos	3	
	Recopilación de recursos disponibles (RR)	Selección del proyecto software	5	
		Generación de recursos	5	
	Definición del alcance del sistema de agentes (DA)	Investigación de arquitecturas del estado del arte	10	
		Búsqueda de proyectos parecidos	5	
		SUBTOTAL	35	
2ª Iteración	Sistema de agentes (SA)	Diseño del sistema	10	
		Implementación de agentes especializados	35	
		Implementación de sistema de comunicación mínima	10	
	Pruebas y evaluación (P)	Pruebas automatizadas	5	
		Integración continua	3	
		SUBTOTAL	63	
3ª Iteración	Sistema de agentes (SA)	Sistema de evaluación	20	
		Captura de datos de evaluación	5	
	Pruebas y evaluación (P)	Evaluación del sistema mínimo	5	
		SUBTOTAL	30	
4ª Iteración	Sistema de agentes (SA)	Mejora de agentes	15	
		Variaciones de orquestación	15	
	Pruebas y evaluación (P)	Evaluación comparativa	5	
		SUBTOTAL	35	
5ª Iteración	Sistema de agentes (SA)	Arquitecturas de interacción alternativas	15	
		Módulos de memoria	15	
		Agentes avanzados	15	
	Pruebas y evaluación (P)	Evaluación comparativa	10	
		SUBTOTAL	55	
6ª Iteración	Ajuste de modelo (AM)	Selección del agente	3	
		Extracción de datos	10	
		Entrenamiento del modelo	20	
	Sistema de agentes (SA)	Incorporación del modelo ajustado	5	
	Pruebas y evaluación (P)	Evaluación comparativa	5	
		SUBTOTAL	43	
	Gestión (G)	Planificación (PL)	15	
		Seguimiento y control (SC)	15	
		SUBTOTAL	30	
	Trabajo académico	Memoria (M)	60	
		Defensa (D)	10	
		SUBTOTAL	70	

Figura 3.4: Estimación horaria de cada tarea



Captura de requisitos

Una vez establecido el objetivo general del proyecto en el Capítulo 1 y asentados los conceptos con los que se trabajará en el Capítulo 2, en el presente capítulo se detallarán los requisitos establecidos para el desarrollo del sistema.

La captura de requisitos se ha estructurado en tres fases: en primer lugar, la definición de los requisitos principales y el alcance general con los directores del proyecto; en segundo lugar, la identificación de los dominios de conocimiento en los que el sistema debe especializarse; y finalmente, la determinación de los recursos específicos a utilizar para la implementación de la solución.

4.1. Requisitos principales

El sistema agéntico implementado debe tener las siguientes características para cumplir con las necesidades del director empresarial:

4.1.1. Requisitos funcionales

- **Agentes especializados:** el sistema contemplará un mínimo de 4 agentes cuya labor esté especializada en responder preguntas sobre fuentes de datos específicas.
- **Fuentes de información:** los agentes del sistema dispondrán de acceso a un conjunto de recursos que incluirá el repositorio de código del proyecto software, una documentación externa y un sistema de gestión de tareas. Al menos una de estas fuentes deberá ser accedida mediante una implementación RAG.

- **Orquestación:** se requiere un agente coordinador cuya función sea decidir a qué agente especializado delegar una acción a realizar.
- **Protocolo MCP:** la implementación priorizará el uso del protocolo MCP: Al menos uno de los agentes especializados empleará dicho protocolo para obtener las herramientas a utilizar.
- **Evaluación de agentes:** se implementará un sistema de evaluación objetiva para determinar si la mejora de agentes incrementa la precisión del sistema. Dado un agente y su mejora, será posible determinar cuál de los dos responde mejor a las preguntas realizadas, utilizando para ello una métrica cuantificable.
- **Enfoque del sistema:** la finalidad principal del sistema consistirá en responder preguntas sobre un proyecto software, logrando una tasa de precisión mínima del 75 % sobre un conjunto predefinido de no menos de 25 preguntas, aprobado por los directores del proyecto. Esta precisión se medirá utilizando una métrica cuantificable previamente establecida.
- **Librerías utilizadas:** el desarrollo se sustentará en tres librerías especializadas: LangChain para el control de modelos y gestión de prompts (empleada en al menos el 75 % de las ejecuciones), LangGraph para estructurar el flujo lógico (requiriendo que mínimo tres cuartas partes de los agentes operen sobre un grafo compilado de dicha librería), y LangSmith como herramienta de monitorización (garantizando la visualización de todas las llamadas a modelos en la plataforma).

4.1.2. Requisitos no funcionales

- **Control de excepciones:** el sistema incorporará un control de excepciones que garantice la ejecución aún si un agente o una herramienta genera una excepción. Se contempla la captura de excepciones de todos los agentes y todas las herramientas utilizadas.
- **Control del tiempo:** la ejecución completa del sistema para un caso de uso no excederá los 5 minutos.
- **Control del presupuesto:** se establece un límite máximo de 25 céntimos por ejecución de un caso de uso para el coste de API de modelos.
- **Independencia de modelos:** la arquitectura garantizará independencia respecto a un único proveedor de modelos LLM. La sustitución de los modelos utilizados será posible en menos de 5 minutos.
- **Modularidad del sistema:** el orquestador funcionará de manera desacoplada respecto a los agentes especializados. La adición o eliminación de un agente especializado requerirá menos de 5 minutos de desarrollo.

4.2. Dominios de conocimiento

De acuerdo con los objetivos previamente establecidos en la Sección 3.1.1, es necesario alinear el sistema con la metodología de desarrollo implementada en la organización. Con este propósito, se ha efectuado una recopilación de las posibles interrogantes dirigidas al sistema, procediendo posteriormente a realizar un análisis de la metodología actualmente vigente en el entorno empresarial.

4.2.1. Anotación de preguntas

Se ha llevado a cabo una elicitación de requisitos mediante la implementación de un cuestionario electrónico dirigido al personal técnico de la sede de Zuatzu en LKS Next. En dicho cuestionario, se solicitó a los profesionales que, acorde a su ámbito de especialización, anotasen las interrogantes que formularían a un sistema de onboarding hipotético.

Se recabaron un total de 63 interrogantes aportadas por 8 profesionales del ámbito del desarrollo software. Posteriormente, dichas cuestiones fueron ampliadas y categorizadas mediante la utilización del modelo Claude 3.7 Sonnet¹ en su versión razonadora, tras lo cual se procedió a una anotación manual para eliminar elementos redundantes. La compilación clasificada final puede consultarse en el Listado B.1, donde se han identificado los siguientes dominios de conocimiento:

En este párrafo tengo dudas con los tiempos verbales. He puesto "se recabaron", "fueron ampliadas", "se procedió", y luego el pretérito perfecto compuesto "se han identificado". Es como mejor me suena, pero no sé si el cambio contrasta demasiado.

- **Información general:** objetivo, finalidad y contexto del proyecto.
- **Entorno y despliegue:** entornos de desarrollo y sistemas de despliegue disponibles.
- **Gestión del proyecto:** comunicación y coordinación del equipo, metodología de contribución y gestión de tareas y requisitos.
- **Estándares y prácticas:** estándares de codificación, estándares visuales, estándares de integración y aspectos legales.
- **Documentación:** información sobre las fuentes de documentación disponibles para el proyecto, incluyendo su ubicación.
- **Recursos adicionales:** recursos externos al proyecto como formaciones y documentación de librerías.

¹Claude 3.7 Sonnet: <https://www.anthropic.com/claude/sonnet>

- **Arquitectura del sistema:** cuestiones de diseño del código fuente sobre todos los niveles de abstracción del modelo C4[60]. Este modelo define los niveles de abstracción de un proyecto software en 4 niveles:
 - Actores y sistemas externos con los que interactúa el sistema
 - Contenedores y aplicaciones que componen el sistema
 - Componentes que definen cada contenedor
 - Diagrama de clases e interfaces de cada componente

4.2.2. Metodología empresarial

La metodología implementada ha sido consultada directamente con los desarrolladores de LKS Next. Al tratarse de una empresa consultora, la metodología aplicada presenta variaciones en función del cliente específico al que se presta servicio. No obstante, se ha identificado que dicha metodología se fundamenta en las siguientes directrices comunes:

- **Gestión del tiempo:** los integrantes del equipo utilizan una aplicación propietaria para el registro y contabilización de las horas invertidas en cada proyecto.
- **Gestión de tareas:** la asignación, seguimiento y monitorización de tareas se efectúa a través de herramientas especializadas como Jira².
- **Documentación:** la documentación técnica y funcional de los proyectos se distribuye en diversas plataformas, incluyendo páginas web específicas o directorios designados dentro del propio repositorio del proyecto.
- **Repositorio del proyecto:** la gestión del código fuente se realiza de manera centralizada en un repositorio común, alojado en plataformas como el GitLab³ propio de LKS Next o GitHub.

Adicionalmente, el flujo de trabajo establecido entre los equipos de diseño y desarrollo sigue una metodología específica. En una entrevista con un miembro del departamento de diseño A.5, se ha documentado el siguiente proceso:

En primera instancia, los requisitos visuales del proyecto se documentan en un repositorio de Confluence⁴ sincronizado con el cliente. Posteriormente, el equipo de diseño elabora un prototipo visual empleando herramientas especializadas como Figma⁵. Una vez aprobados los diseños, estos se transforman en maquetas HTML funcionales, las cuales son compartidas con el equipo de desarrollo a través del sistema de almacenamiento en la nube de Google Drive.

²Jira: <https://www.atlassian.com/es/software/jira>

³GitLab: <https://about.gitlab.com/>

⁴Confluence: <https://www.atlassian.com/es/software/confluence>

⁵Figma: <https://www.figma.com/>

4.3. Recursos a utilizar

Tras definir los requisitos fundamentales y los dominios de conocimiento necesarios, se requiere establecer el contexto específico donde integrar el sistema a desarrollar.

4.3.1. Proyecto software

Debido a las restricciones legales existentes, no es viable la utilización de proyectos de cliente en entornos de producción. Bajo estas restricciones, para el desarrollo del presente trabajo se ha seleccionado el proyecto propietario IA-core-tools. Este constituye un conjunto de herramientas para el desarrollo de agentes basados en LLM con capacidad de acceso a fuentes de información mediante RAG. La aplicación está implementada en Flask⁶ y proporciona una API que facilita el desarrollo de agentes de manera interactiva a través de una interfaz visual, permitiendo a los desarrolladores de LKS Next crear soluciones para proyectos en producción.

Se dispone de acceso completo al repositorio de GitLab del proyecto, lo que proporciona información detallada sobre todos los usuarios, contribuciones realizadas, gestión de incidencias y administración de tareas. Asimismo, se dispone de las maquetas HTML utilizadas para crear la interfaz de usuario.

Cabe destacar que la metodología de gestión implementada difiere ligeramente de la empleada en proyectos orientados directamente a clientes. En este caso, el desarrollador principal es Aritz Galdos (director empresarial del presente proyecto), quien coordina reuniones tanto presenciales como virtuales con los contribuyentes del proyecto. Debido a las restricciones legales mencionadas anteriormente, no se dispone de acceso a la aplicación de gestión horaria del proyecto.

4.3.2. Recursos generados

Con el objetivo de una evaluación detallada del sistema, se ha procedido a la generación de documentación que replica con la mayor fidelidad posible las características del proyecto original. Para este propósito, se ha empleado nuevamente el modelo Claude 3.7 Sonnet, utilizando como datos de entrada toda la información de gestión previamente mencionada, así como ficheros clave extraídos del repositorio del código fuente. Posteriormente, se ha realizado un proceso de refinamiento manual de la documentación generada con el objetivo de eliminar imprecisiones e información errónea.

En una primera fase, se han elaborado tres documentos específicos relacionados con la sección visual del proyecto: funcionamiento_y_diseno_interfaz, guia_de_estilos_visual y limitaciones_y_mejoras_pendientes. Estos documentos han sido incorporados a un repositorio de Confluence para simular la documentación habitualmente proporcionada por los diseñadores del equipo.

⁶Flask: <https://flask.palletsprojects.com/en/stable/>

Seguidamente, se han desarrollado trece documentos que constituyen una simulación de la “documentación oficial” del proyecto. Estos documentos recogen los elementos necesarios para la comprensión de la gestión, diseño y metodología de contribución del proyecto: `arquitectura-software.md`, `despliegue.md`, `equipo-y-comunicacion.md`, `estandares-codigo.md`, `flujos-trabajo.md`, `guia-contribucion.md`, `informacion-cliente.md`, `metodologia.md`, `modelo-negocio.md`, `onboarding.md`, `README.md`, `referencias-tecnicas.md` y `sistema-gestion-tareas.md`.

Por último, se ha generado la “Documentación API” del proyecto mediante la utilización del agente RepoAgent[61]. Esta documentación contiene explicaciones detalladas de todas las clases y métodos implementados en Python, que conforman la estructura del dominio y del modelo de negocio. El uso de este agente externo se explica detalladamente en la sección ??.

Como he usado la documentación API para indexar los chunks de código, creo que lo mejor es explicarlo en esa sección.

Diseño del sistema

Tras establecer los parámetros necesarios correspondientes a la gestión del proyecto, este capítulo presenta el diseño del sistema implementado. Para ello se introducirá la estructura de directorios utilizada, el diseño del software desarrollado y la gestión de las herramientas con el protocolo MCP.

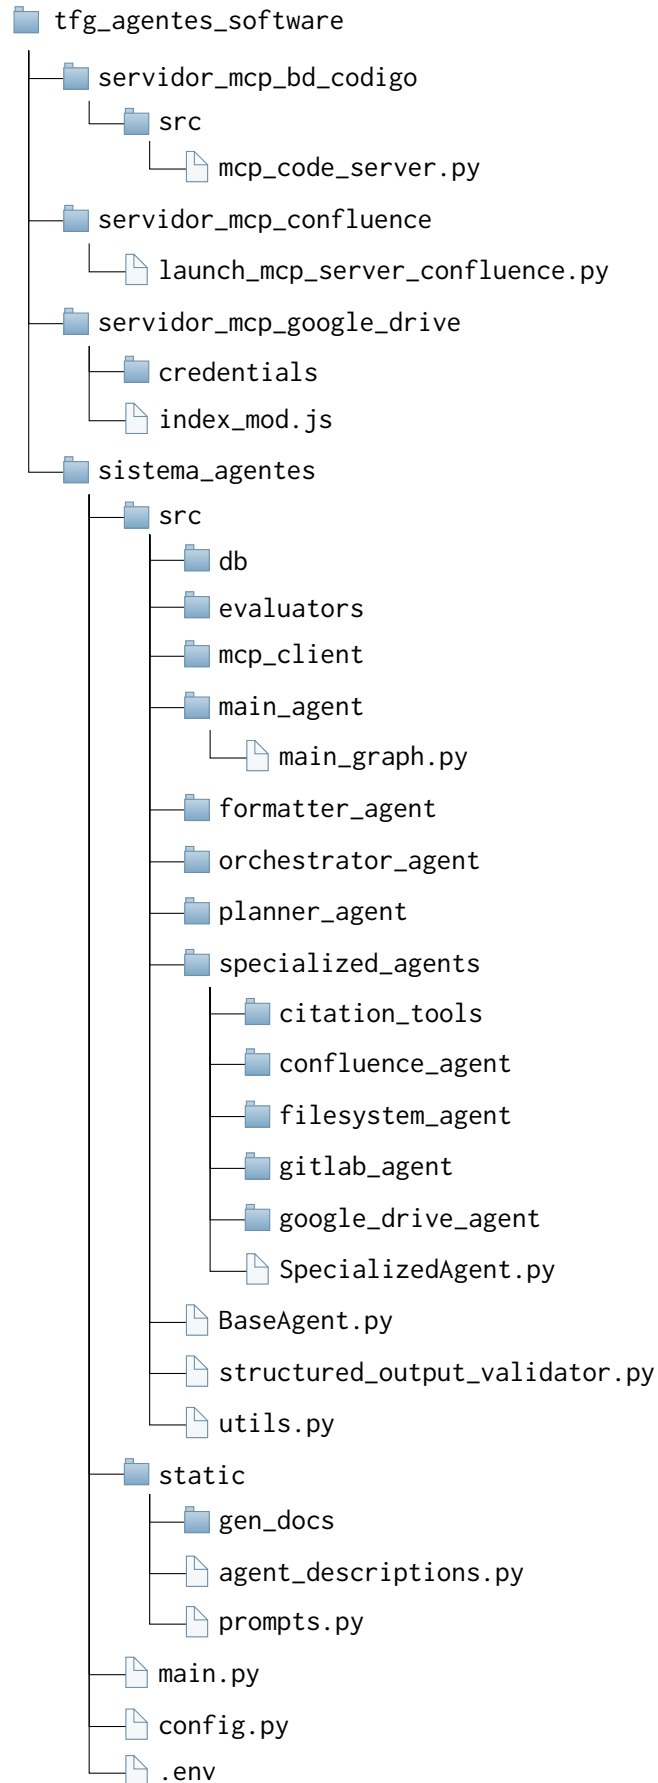
5.1. Estructura del proyecto

El repositorio se estructura en cuatro componentes independientes, cada uno con su propio entorno virtual de Python (venv¹). La Figura 5.1 ilustra la organización jerárquica de los directorios principales.

El componente `sistema_agentes` alberga todos los agentes desarrollados junto con los clientes MCP. La implementación de los agentes se ubica en el directorio `src`, mientras que `static` contiene los prompts utilizados, las descripciones de los agentes y la documentación generada. El archivo `.env` almacena variables secretas como las claves de acceso a APIs, y el archivo `config.py` gestiona variables globales como el modelo predeterminado utilizado en los agentes. El archivo `main.py` integra la lógica de ejecución principal, mientras que `src/main_agent/main_graph.py` implementa el agente principal `MainAgent`.

Los directorios `servidor_mcp_bd_codigo`, `servidor_mcp_confluence` y `servidor_mcp_google_drive` contienen cada uno un servidor MCP.

¹venv: <https://docs.python.org/3/library/venv.html>

**Figura 5.1:** Estructura de directorios principales del proyecto

5.2. Diseño de agentes

LangGraph proporciona un marco de trabajo estructurado para la creación de flujos de ejecución en forma de grafo. Inicialmente se construye un grafo mediante el objeto `StateGraph`, el cual establece la lógica de enrutamiento entre diversos nodos definidos como funciones de Python. Estos grafos utilizan un denominado estado, representado por un diccionario tipado, para almacenar el estado de ejecución durante el proceso.

Debería referenciar en el pie de página la documentación de las clases de las librerías que menciono? Me ha dicho Claude que sobrecargaría demasiado la memoria.

Bajo este paradigma, un agente puede representarse como un grafo compilado, en el cual uno o varios nodos definen la lógica de invocación a los modelos LLM, mientras que otros nodos se encargan de interpretar el resultado. En una implementación tradicional, el estado conservaría los mensajes generados entre llamadas, lo que posibilita un proceso iterativo donde el nodo de invocación al LLM se ejecuta repetidamente, añadiendo un nuevo mensaje al estado en cada ciclo de ejecución.

Estos dos párrafos quizás quedarían mejor en una breve sección en antecedentes?

Este enfoque proporciona un marco de trabajo orientado a la composición, donde un nodo puede constituir a su vez otro grafo compilado que represente a otro agente. No obstante, surge una problemática de redundancia cuando dos agentes comparten gran parte del grafo que los compone. Para evitar la duplicación de código, podría desarrollarse un grafo que contemple la ejecución de ambos tipos de agentes, determinando cuál ejecutar según un parámetro en el estado. Si bien esta solución es viable, la programación orientada a objetos ofrece una alternativa más elegante: la herencia.

Es por este motivo que se ha optado por un enfoque híbrido que combina composición y herencia. Cada agente está implementado mediante una clase de Python, la cual contiene la función `create_graph()`, encargada de componer el grafo representativo de la ejecución del agente. De este modo, la clase del agente define las funciones que representan cada nodo del grafo, pudiendo heredar aquellas definidas en clases más abstractas.

Adicionalmente, esta metodología facilita el almacenamiento de datos no vinculados a la ejecución individual. Los datos encapsulados en los atributos de las clases representan información invariable en cada ejemplo de ejecución, como el nombre del agente o las herramientas disponibles; mientras que los atributos almacenados en el estado del grafo son específicos de la ejecución, como los mensajes generados durante la instancia de ejecución concreta.

5.2.1. Diagrama de agentes

La Figura 5.2 ilustra el diagrama de clases (UML) general del sistema, donde se puede observar que la clase abstracta `BaseAgent` constituye la base de la que heredan todos los agentes. Dicha clase establece las funcionalidades comunes que implementan todos los agentes del sistema:

- **Lógica de ejecución:** la función `execute_agent_with_exception_handling()` se encarga de invocar el grafo definido en la función `create_graph()`, gestionando las posibles

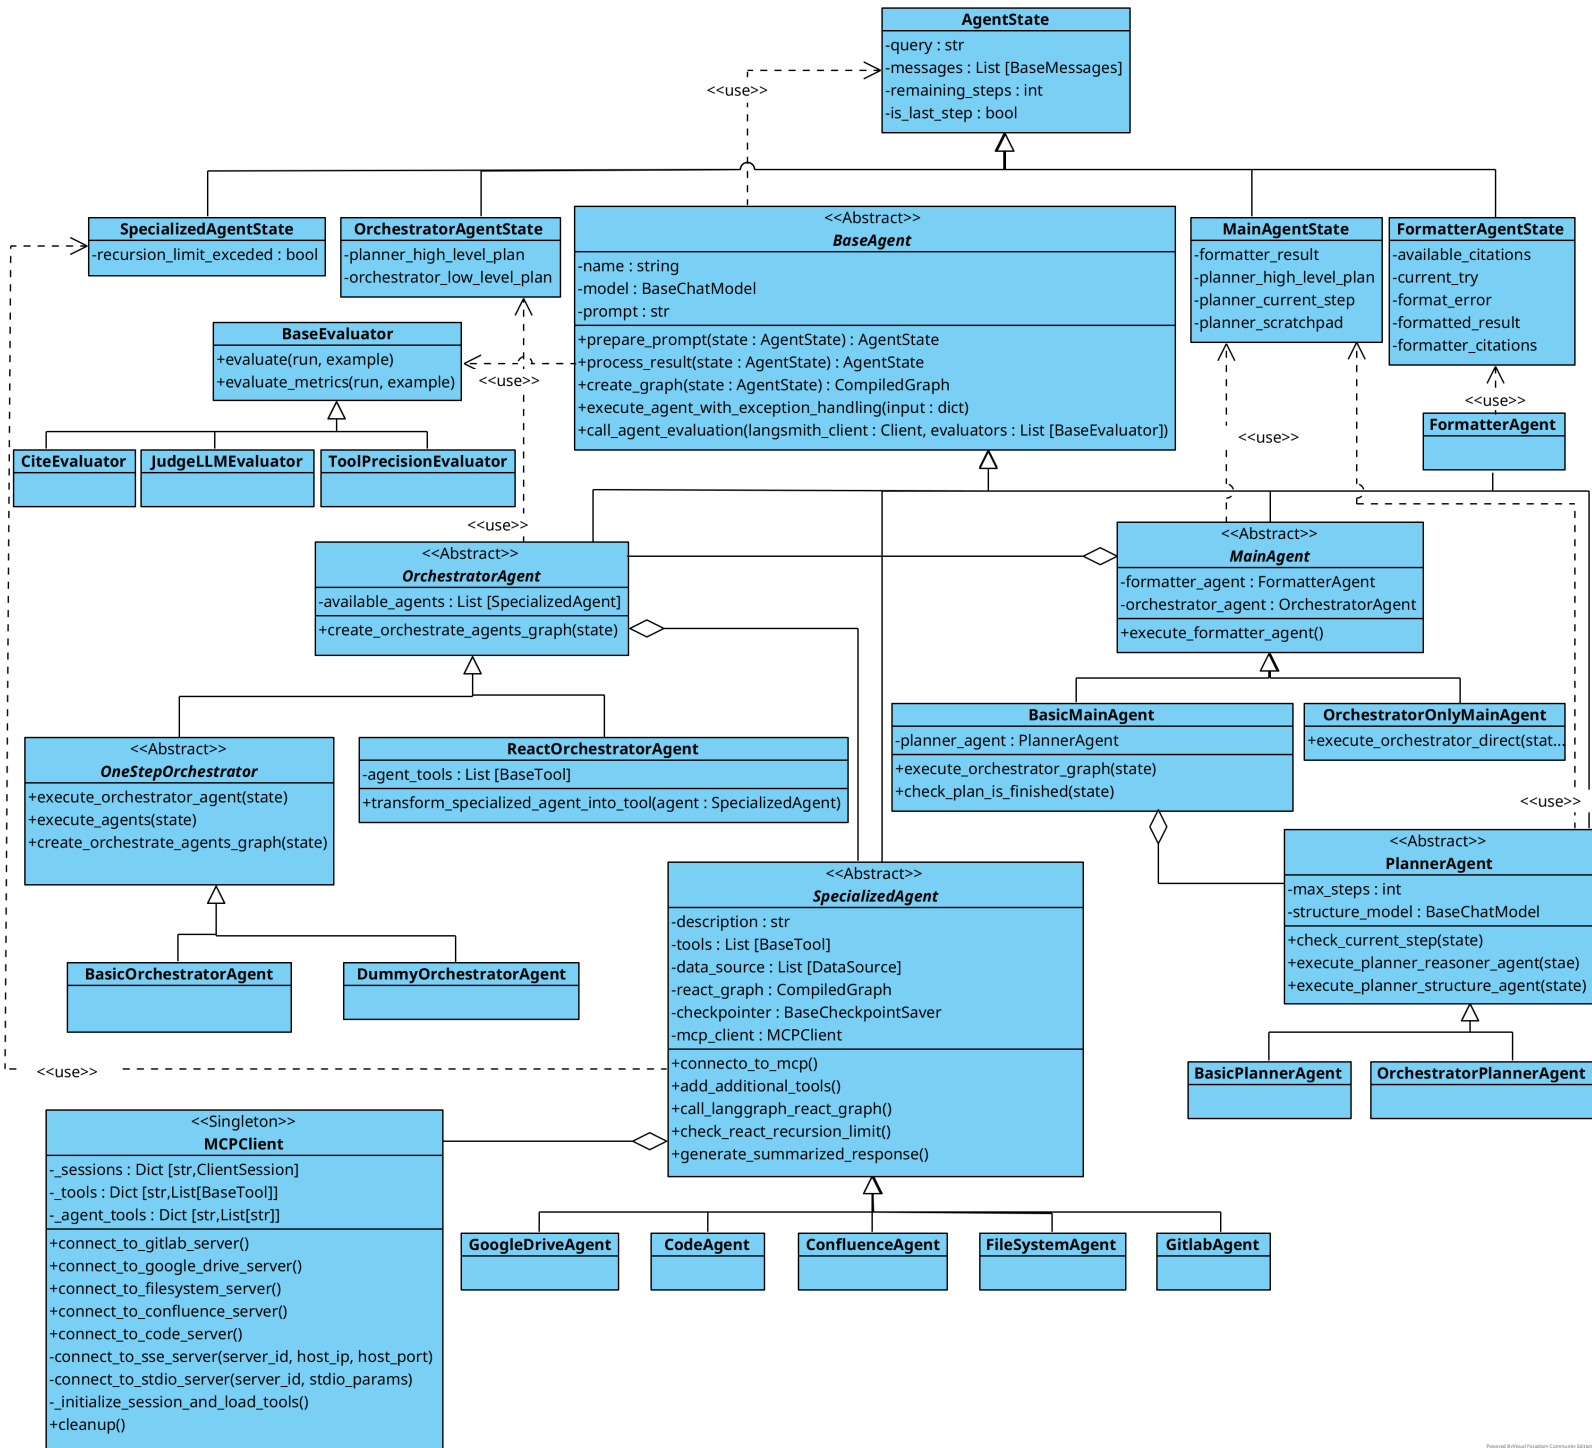


Figura 5.2: Diagrama de clases UML de del sistema de agentes.

excepciones e inicializando los parámetros de entrada requeridos. Todos los agentes derivados deben implementar la función `prepare_prompt()` e integrarla en su grafo de ejecución correspondiente, para definir el mensaje inicial del sistema que instruye al agente.

- **Gestión del resultado:** la función `process_result()` se encarga de procesar y devolver de manera estática el resultado de ejecución del agente para un estado de ejecución determinado. Dependiendo del agente concreto, este resultado puede comprender todos los mensajes que satisfagan determinados criterios establecidos.
- **Evaluación del agente:** la función `call_agent_evaluation()` establece la lógica de evaluación específica para cada agente, utilizando las métricas definidas y representadas por la clase `BaseEvaluator`. El Capítulo ?? describe este proceso en detalle.

Los agentes que heredan del agente base son los siguientes:

- **SpecializedAgent:** representa de forma abstracta los agentes que realizan búsquedas en fuentes de información especializadas, aspecto detallado en la Sección ?. Integra la lógica de gestión de las herramientas utilizadas mediante la clase `MCPClient`, explicada en la Sección 5.4. Asimismo, contiene una secuencia de instancias de `DataSource`, las cuales definen todos los documentos citables en las fuentes de datos disponibles, descrita en la Sección ?.
- **OrchestratorAgent:** implementa la lógica de enrutamiento de los agentes especialistas, determinando en cada caso qué agentes ejecutar para resolver una cuestión específica. Véase la Sección ?.
- **PlannerAgent:** define la estrategia de planificación a seguir para una consulta determinada, elaborando planes secuenciales dinámicamente adaptables. Este proceso se detalla en la Sección ?.
- **FormatterAgent:** transforma una secuencia de ejecución de agentes en un resultado estructurado y comprensible, compuesto por una respuesta en formato textual y un conjunto de citas que referencian a documentos del proyecto software. Consulte la Sección ?.
- **MainAgent:** establece el flujo general de la ejecución, especificando si se implementarán agentes planificadores, orquestadores y enlazando su respuesta al agente formateador. Este proceso se describe en la Sección ?.

Cada agente implementa su propia clase de estado para gestionar los atributos vinculados a una ejecución específica. Estas clase extienden el estado común `AgentState`, que incorpora atributos como los mensajes a incluir en el contexto de entrada. Como se ha descrito en la Sección 2.2.3, la interacción con los agentes sigue una estructura conversacional. Para implementar esta estructura, se utiliza la implementación de mensajes de `LangChain: SystemMessage` para las instrucciones

que instruyen al agente, `HumanMessage` para las consultas o mensajes del usuario, y `AIMessage` para incorporar comunicaciones de agentes precedentes en el contexto de entrada.

Durante la fase de inicialización, se procede a la creación de los grafos correspondientes a todos los agentes mediante la instanciación de sus respectivas clases, estableciendo simultáneamente las conexiones necesarias con los servidores MCP. Una vez completado este proceso de inicialización, los agentes adquieren la capacidad de responder a todas las consultas requeridas sin necesidad de reconexión.

5.3. Servidores MCP utilizados

En esta sección se describirán los cinco servidores MCP utilizados, los cuales exponen sus herramientas mediante los dos protocolos de comunicación introducidos en la Sección 2.3: el protocolo SSE (Server-Sent Events) y el protocolo STDIO (Standard Input/Output).

5.3.1. Servidores SSE

Estos se alojan en componentes separados, ya que el protocolo SSE permite desacoplar servidores y cliente MCP.

- **Servidor Confluence:** proporciona acceso de lectura al repositorio Confluence, utilizando el servidor MCP oficial de Atlassian². El componente `servidor_mcp_confluence` incorpora un script de lanzamiento `launch_mcp_server_confluence.py` (detallado en el listado 5.1), un entorno virtual `.venv` y un archivo `.env` destinado al almacenamiento de credenciales de Confluence.

El script inicializa el servidor mediante el gestor de paquetes `uv`, implementando el paquete `mcp-atlassian`³ disponible en PyPI⁴. Atlassian integra el Kit de desarrollo de software (SDK) del protocolo MCP⁵ en este paquete para desarrollar un servidor de Interfaz de Pasarela de Servidor Asíncrona (ASGI) con capacidades de enrutamiento de herramientas que interactúan con su API. Tras la extracción de variables de entorno desde `.env`, la biblioteca `subprocess`⁶ ejecuta el comando `uvx` en el sistema, requiriendo que `uvx` esté previamente instalado en el entorno virtual del componente.

Listing 5.1: `launch_mcp_server_confluence.py`: ejecución de lanzamiento del servidor MCP Confluence

```
1      # Obtener variables de entorno
2      load_dotenv() # <- Carga las variables desde el fichero .env
```

²Repositorio de servidor MCP Atlassian: <https://github.com/sooperset/mcp-atlassian>

³Paquete `mcp-atlassian`: <https://pypi.org/project/mcp-atlassian/>

⁴PyPI: <https://pypi.org/>

⁵SDKs del protocolo MCP: <https://github.com/modelcontextprotocol>

⁶Librería `subprocess`: <https://docs.python.org/3/library/subprocess.html>

```

3     confluence_url = os.getenv('CONFLUENCE_URL')
4     ...
5
6     # Construir el comando para uvx
7     command = ["uvx", "mcp-atlassian"]
8
9     command.extend(["--transport", mcp_transport])
10    command.extend(["--port", mcp_port])
11    command.extend(["--confluence-url", confluence_url])
12    command.extend(["--confluence-username", confluence_username])
13    command.extend(["--confluence-token", confluence_token])
14
15    # Ejecutar el comando
16    try:
17        subprocess.run(command)
18    ...

```

- **Servidor Código:** proporciona acceso de lectura al repositorio software, implementando herramientas para la consulta de su código fuente. Su desarrollo se ha realizado directamente mediante el SDK de MCP para Python⁷, localizado en el fichero `src/mcp_code_server.py` del componente `servidor_mcp_bd_codigo`. La Sección ?? detalla la implementación de dichas herramientas.

El sistema emplea la clase `FastMCP`, que integra internamente un servidor ASGI mediante la librería `Starlette`⁸ para gestionar el enrutamiento de las herramientas implementadas. Como se especifica en el Listado 5.2, el procedimiento consta de la instanciación de la clase, la asociación de diversas herramientas mediante el decorador `mcp.tool()`, y la posterior ejecución del servidor. Una vez vinculadas las herramientas, se generan automáticamente las rutas `call_tool` y `get_tools`, facilitando su acceso desde el cliente MCP.

Listing 5.2: `mcp_code_server.py`: ejecución del servidor MCP con acceso al código fuente

```

1     # Instanciar clase
2     mcp = FastMCP("postgre")
3
4     # Vincular herramientas al servidor
5     @mcp.tool()
6     async def get_all_respository_files_list() -> TextContent:
7         """
8         Devuelve una lista en formato string serializable a JSON de todos los
9         ficheros en el repositorio respecto a su ruta relativa
10        """

```

⁷SDK de MCP para Python: <https://github.com/modelcontextprotocol/python-sdk>

⁸Librería Starlette: <https://www.starlette.io/>

```

10     files_list = get_all_files_list(db_session=db_session)
11     files_list_str=str(files_list)
12     return TextContent(
13         text=files_list_str,
14         type='text'
15     )
16
17     # Ejecutar servidor
18     if __name__ == "__main__":
19         try:
20             mcp.run(transport='sse')
21         ...

```

5.3.2. Servidores STUDIO

Estos servidores se ejecutan estableciendo una conexión en el cliente MCP mediante una instancia de `StdioServerParameters`, que especifica los parámetros de configuración necesarios. De esta manera, cuando el cliente inicia la conexión, el servidor se ejecuta en un subproceso del mismo.

La configuración de dicha instancia sigue en los tres servidores el mismo procedimiento ilustrado en el Listado 5.3. Se construye el comando con los argumentos correspondientes y se incorporan las credenciales como variables de entorno.

Listing 5.3: `mcp_multi_client.py`: instanciado de `StdioServerParameters` para el servidor MCP de GitLab

```

1     # Crear comando y argumentos
2     server_command = "npx"
3     server_args = ["-y", "@modelcontextprotocol/server-gitlab"]
4
5     # Obtener las credenciales desde las variables de entorno
6     server_env = {
7         "GITLAB_PERSONAL_ACCESS_TOKEN": os.getenv('GITLAB_PERSONAL_ACCESS_TOKEN'),
8         "GITLAB_API_URL": GITLAB_API_URL
9     }
10
11     # Crear instancia StdioServerParameters indicando las credenciales de GitLab como
12     # variables de entorno
13     server_params = StdioServerParameters(
14         command=server_command,
15         args=server_args,
16         env=server_env
17     )

```

Mediante este procedimiento, se han utilizado los siguientes servidores:

- **Servidor Sistema de ficheros local:** proporciona acceso a un directorio específico, que simula el repositorio de la “documentación oficial” del proyecto. Se ha utilizado el servidor de Anthropic FileSystem⁹, ejecutándolo mediante el comando npx con el paquete del registro npm¹⁰ @modelcontextprotocol/server-filesystem¹¹.
- **Servidor GitLab:** facilita el acceso al repositorio de GitLab con funcionalidades para leer o modificar ficheros, incidencias, usuarios y contribuciones. Se ejecuta utilizando el paquete npm @modelcontextprotocol/server-gitlab¹². Debido a que no ofrece capacidades específicas para la lectura de ciertos recursos (limitándose a operaciones de escritura), se han incorporado herramientas complementarias mediante la función add_additional_tools() en el agente SpecializedAgent, como se detalla en la Sección ??.
- **Servidor Google Drive:** proporciona acceso a un directorio de Google Drive, donde se alojan las maquetas HTML del proyecto software. A pesar de existir un repositorio oficial de MCP para la conexión con Google Drive, este no ofrece todas las funcionalidades requeridas, por lo que se ha empleado una modificación desarrollada en JavaScript¹³. En consecuencia, en lugar de especificar el paquete a utilizar en la instancia StdioServerParameters, se indica la ruta del script a ejecutar, como se muestra en el Listado 5.4.

Listing 5.4: mcp_multi_client.py: StdioServerParameters para el servidor MCP de Google Drive

```

1  # Construir el comando indicando el script a ejecutar
2  server_script_path = f"{server_path}/index_mod.js"
3  server_command = "node"
4  server_args = [server_script_path]
5
6  server_params = StdioServerParameters(
7      command=server_command,
8      args=server_args,
9      env=env
10 )

```

Adicionalmente, se ha modificado la herramienta de listar ficheros para mostrar recursivamente todos los ficheros dentro de los directorios listados como se muestra en el Listado 5.5

Este fragmento de código quizás no es necesario?

Listing 5.5: index_mod.js: herramienta gdrive_list_files utilizando la API de Google Drive

```

1  // Utilizar librería de google drive para interactuar con la api
2  import { google } from "googleapis";

```

⁹FileSystem: <https://github.com/modelcontextprotocol/servers/tree/main/src/filesystem>

¹⁰Npm: <https://www.npmjs.com/>

¹¹Server-filesystem: <https://www.npmjs.com/package/@modelcontextprotocol/server-filesystem>

¹²Server-gitlab: <https://www.npmjs.com/package/@modelcontextprotocol/server-gitlab>

¹³Servidor MCP Google Drive: <https://github.com/felores/gdrive-mcp-server/blob/main/index.ts>

```

3  const drive = google.drive("v3");
4
5  // Consultar archivos en la carpeta actual
6  const res = await drive.files.list({
7    q: `'${folderId}' in parents`,
8    pageSize: 1000,
9    fields: "files(id, name, mimeType, modifiedTime, size)"
10  });
11
12  // Procesar cada archivo/carpeta
13  for (const file of res.data.files || []) {
14    allFiles.push({
15      ...
16    });
17
18    // Si es una carpeta, listar su contenido recursivamente
19    if (file.mimeType === 'application/vnd.google-apps.folder') {
20      const subFiles = await listFilesRecursively(file.id, depth + 1,
21      maxDepth);
22      allFiles = allFiles.concat(subFiles);
23    }
24  }

```

Para obtener acceso al directorio de Google Drive mediante la API, se ha configurado una aplicación en Google Cloud¹⁴ siguiendo las directrices establecidas en el servidor MCP de Google Drive oficial¹⁵. En dicha plataforma se han obtenido las credenciales de acceso, las cuales se encuentran almacenadas en `mcp_google_drive/credentials/gcp-oauth.keys.json`.

La API requiere adicionalmente de autenticación mediante el protocolo OAuth2.0¹⁶ con la cuenta de Google. Para la generación del token temporal `.gdrive-server-credentials.json`, es necesario ejecutar el script del servidor especificando el parámetro `auth`. Este proceso utilizará la biblioteca `google-cloud/local-auth`¹⁷, la cual iniciará el protocolo de autenticación en el navegador.

5.4. Cliente MCP

Una vez explicada la estructura general de agentes y servidores MCP, en esta sección se detallará el mecanismo de comunicación entre los agentes y sus respectivos servidores para acceder a las herramientas disponibles.

¹⁴Google Cloud: <https://cloud.google.com/?hl=es>

¹⁵Directrices de autenticación: <https://github.com/modelcontextprotocol/servers/tree/main/src/gdrive>

¹⁶OAuth2.0: <https://oauth.net/2/>

¹⁷Local-auth: <https://www.npmjs.com/package/@google-cloud/local-auth>

Se ha implementado un cliente MCP mediante el patrón Singleton¹⁸ que permite gestionar todas las conexiones activas con los servidores MCP. Esta clase mantiene un diccionario para todas las herramientas y sesiones de conexiones MCP, utilizando el identificador del servidor como clave, tal como se ilustra en el Listado 5.6.

Listing 5.6: `mcp_multi_client.py`: clase Singleton MCPClient

```
1 class MCPClient:
2     _instance = None
3
4     # Sesiones con servidores, diccionario de server_id, Session
5     _sessions: Dict[str, ClientSession] = {}
6     # Herramientas disponibles por cada servidor
7     _tools: Dict[str, List[BaseTool]] = {}
8     # Nombres de las herramientas requeridas por cada agente
9     _agent_tools: Dict[str, List[str]] = {}
```

Quizás no es necesario este fragmento de código?

Para acceder a las herramientas de un agente, se debe seguir un procedimiento secuencial que consiste en registrar inicialmente el agente para indicar las herramientas que este necesita, establecer la conexión con el servidor correspondiente, y posteriormente obtener las herramientas mediante el cliente, según se ilustra en el Listado 5.7.

Listing 5.7: `google_drive_agent_graph.py`: función `connect_to_mcp` en agente Google Drive

```
1 async def connect_to_mcp(self):
2     self.mcp_client = MCPClient.get_instance()
3     await self.mcp_client.connect_to_google_drive_server()
4
5     self.mcp_client.register_agent(self.name, self.tools_str)
6     self.tools = self.mcp_client.get_agent_tools(self.name)
```

Las operaciones anteriormente descritas invocarán la función de conexión con el servidor correspondiente, siguiendo dos patrones distintos según el tipo de conexión: para conexiones STDIO, como en el caso de `connect_to_google_drive_server()` (Listado 5.8), se generarán los parámetros STDIO conforme al procedimiento detallado en la Sección 5.3.2, y se ejecutará la función `connect_to_stdio_server()` (Listado 5.9); mientras que para conexiones SSE, la función correspondiente obtendrá la dirección del servidor para posteriormente establecer la conexión mediante la función `connect_to_sse_server()`, como se ilustra en el Listado 5.10.

Las conexiones implementan el SDK de MCP para Python, generando objetos `ClientSession` dentro de una pila de salida asíncrona (`AsyncExitStack`) denominada `global_exit_stack`, definida a nivel global para gestionar la liberación ordenada de recursos de todos los agentes. Esta estructura permite registrar múltiples gestores de contexto asíncronos que serán cerrados automáticamente

¹⁸Patrón Singleton: <https://refactoring.guru/es/design-patterns/singleton>

en orden inverso. Al finalizar la ejecución, la función `cleanup()` del cliente MCP cierra esta pila de salida, terminando así todas las conexiones establecidas de manera controlada, tal como se detalla en el Listado 5.11.

Listing 5.8: `mcp_multi_client.py`: función `connect_to_google_drive_server` en el cliente MCP

```

1  async def connect_to_google_drive_server(self):
2      server_id = "google_drive"
3      ...
4      await self.connect_to_stdio_server(server_id, server_params)

```

Listing 5.9: `mcp_multi_client.py`: función `connect_to_stdio_server` en el cliente MCP

```

1  async def connect_to_stdio_server(self, server_id: str, stdio_params:
    StdioServerParameters):
2      # Establecer la conexión usando el exit_stack global
3      stdio_transport = await global_exit_stack.enter_async_context(stdio_client(
        stdio_params))
4      stdio, write = stdio_transport
5
6      # Crear la sesión
7      session = await global_exit_stack.enter_async_context(ClientSession(stdio,
        write))
8      self._sessions[server_id] = session
9
10     await self._initialize_session_and_load_tools(server_id)

```

Listing 5.10: `mcp_multi_client.py`: función `connect_to_sse_server` en el cliente MCP

```

1  async def connect_to_sse_server(self, server_id: str, host_ip: str, host_port: int
    ):
2      # Usar el exit_stack global
3      streams = await global_exit_stack.enter_async_context(
4          sse_client(f"http://{host_ip}:{host_port}/sse")
5      )
6
7      session = await global_exit_stack.enter_async_context(
8          ClientSession(streams[0], streams[1])
9      )
10     self._sessions[server_id] = session
11
12     await self._initialize_session_and_load_tools(server_id)

```

Listing 5.11: `mcp_multi_client.py`: función `cleanup()` en el cliente MCP


```
1 @staticmethod
2 async def cleanup():
3     try:
4         if global_exit_stack:
5             await global_exit_stack.aclose()
6     ...
```

En ambos protocolos de conexión se invoca finalmente la función `_initialize_session_and_load_tools()`, ilustrada en el Listado 5.12. Esta función inicializa la sesión de la conexión y adapta las herramientas MCP a objetos `BaseTool` de `LangChain` mediante la función `load_mcp_tools()`. Adicionalmente, la función `patch_tool_with_exception_handling()` constituye otro adaptador que incorpora un bloque de manejo de excepciones para impedir que los errores en las herramientas se propaguen a la ejecución del agente.

Listing 5.12: `mcp_multi_client.py`: función `_initialize_session_and_load_tools` en el cliente MCP

```
1 async def _initialize_session_and_load_tools(self, server_id: str):
2     await self._sessions[server_id].initialize()
3
4     # Adaptar herramientas a BaseTool de LangChain
5     tools = await load_mcp_tools(self._sessions[server_id])
6     # Añadir control de excepciones a las herramientas
7     wrapped_tools = [patch_tool_with_exception_handling(tool) for tool in tools]
8
9     self._tools[server_id] = wrapped_tools
```


Agentes especializados

Una vez introducido el diseño general del sistema, en este capítulo se explicarán los agentes especializados que acceden a las fuentes de datos del proyecto software.

Para ello primero se introducirá la estructura de la base común `SpecializedAgent`, tras lo que se detallarán tanto las herramientas como el grafo de los cinco agentes especialistas que extienden esta base.

6.1. Estructura `SpecializedAgent`

El grafo común de este agente se divide en tres pasos generales; la configuración del prompt inicial a utilizar mediante la función `prepare_prompt()` heredada de `BaseAgent`, la ejecución de un subgrafo que implementa el patrón ReAct (Véase Sección ??) y la ejecución de un agente resumidor en caso de ser necesario. La ejecución del grafo general se ilustra en la Figura 6.1.

El grafo ReAct se ha implementado utilizando el agente prefabricado `create_react_agent()` de `LangGraph`. Este agente acepta una serie de herramientas y un prompt inicial y entra en un bucle de ejecución en el que el agente llama a herramientas y observa su resultado. El grafo finaliza su ejecución cuando el mensaje del agente no contiene llamadas a herramientas, es decir, cuando contiene la respuesta final.

Se ha establecido un límite de iteraciones que el grafo ReAct puede ejecutar, ya que se ha observado que en ocasiones entra en un bucle de ejecución excesivamente extenso al no encontrar la información requerida. De esta forma, en caso de llegar al límite de iteraciones, un agente resumidor intenta generar una respuesta con la información disponible observando todas las ejecuciones de las herramientas. En el Listado 6.1 se ilustra la función que define el grafo explicado.

Listing 6.1: `create_graph:Grafodeagentesespecializados`

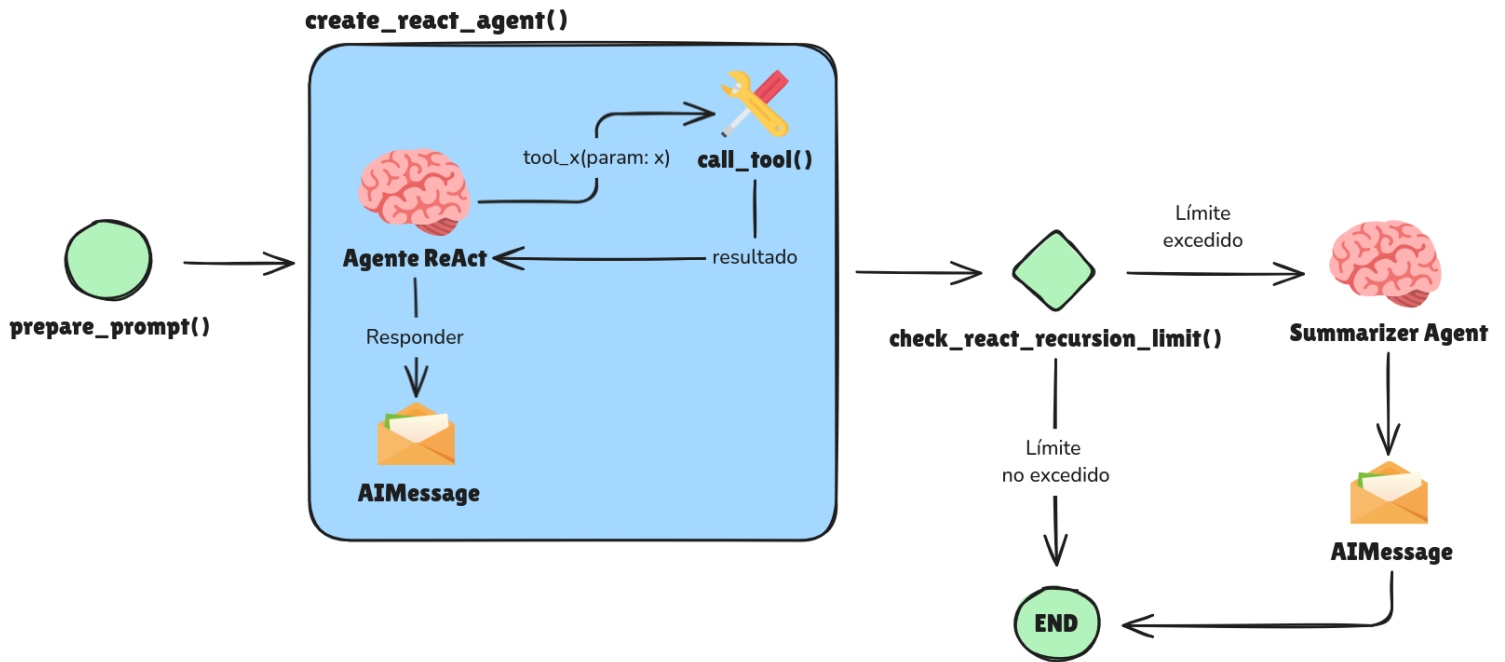


Figura 6.1: Grafo de ejecución de agentes especializados

```

1  def create_graph(self) -> CompiledGraph:
2      # Crear grafo ReAct
3      agent_tools = self.get_agent_tools()
4      self.react_graph = create_react_agent(
5          model=self.model,
6          tools=agent_tools,
7          checkpointer=self.checkpointer
8      )
9
10     # Crear grafo del SpecializedAgent
11     graph_builder = StateGraph(AgentState)
12
13     # Añadir nodos
14     graph_builder.add_node("prepare", self.prepare_prompt)
15     graph_builder.add_node("react", self.call_langgraph_react_graph)
16     graph_builder.add_node("response_summarizer", self.generate_summarized_response)
17
18     # Establecer flujo entre nodos
19     graph_builder.set_entry_point("prepare")
20     graph_builder.add_edge("prepare", "react")
21     graph_builder.add_conditional_edges("react", self.check_react_recursion_limit)

```

```
22  
23     return graph_builder.compile()
```

Para acceder al estado de ejecución del agente ReAct tras finalizar abruptamente su ejecución por el límite de mensajes, se ha utilizado el sistema de autoguardado de LangGraph. Para ello, en la inicialización del agente se crea un objeto `AsyncPostgresSaver`, vinculado tanto a la base de datos PostgreSQL mediante un *Pool* de conexión asíncrono ?? como al contexto de cierre asíncrono `global_exit_stack`. De esta forma, se guardan en una colección de Postgres todos los estados de ejecución, y se pueden acceder indicando su identificador. El uso del guardador asíncrono evita problemas de concurrencia al ejecutar varios agentes asíncronos.

6.1.1. Gestión de herramientas

Algunas herramientas proporcionadas por los servidores MCP son innecesarias o contraproducentes para algunos agentes. Para evitar incluir en el prompt de los agentes contenido innecesario, se debe indicar al instanciar un agente el nombre de las herramientas que se van a utilizar, para posteriormente filtrar las herramientas en el cliente.

Adicionalmente, algunos servidores MCP no proporcionan todas las funcionalidades necesarias. Para obtener estas herramientas adicionales, la función `add_additional_tools()` añade en cada caso herramientas adicionales de ser necesario.

6.2. Agentes implementados

En esta sección se detallarán los cinco agentes desarrollados que extienden las funcionalidades explicadas en la sección anterior.

6.2.1. Agente código

Para obtener información sobre el código fuente del repositorio del proyecto software, el flujo de este agente sigue el siguiente proceso: mediante `prepare_prompt()` se incluye en el prompt del sistema el árbol de directorios del repositorio obtenido con la herramienta `get_repository_tree_tool` y fragmentos de código, denominados *chunks*, relevantes para la consulta actual obtenidos mediante la herramienta `get_code_repository_rag_docs_from_query_tool`. Tras concatenar la consulta al agente mediante un `HumanMessage`, este tiene que decidir si buscar *chunks* adicionales sobre un subdirectorio concreto indicando otra consulta, buscar ficheros específicos con la herramienta `get_file_from_repository_tool` indicando su ruta relativa, o responder directamente a la consulta.

6.2.1.1. Herramientas de acceso a código

Para implementar las herramientas de este agente, en el componente `servidor_mc_bd_codigo` se han dividido los ficheros del proyecto GitLab en *chunks* y posteriormente se han indexado en la base de datos Postgres.

Para implementar este sistema RAG, se ha utilizado la extensión PGVector sobre PostgreSQL. Dicha extensión ofrece la opción de mezclar vectores embeddings en una tabla SQL tradicional, proporcionando operaciones de búsqueda semántica combinadas con operaciones SQL. Para ello, se ha definido el modelo relacional ilustrado en la Figura 6.2, implementando el modelo ORM de SQLAlchemy sobre Python. El diseño se basa en una tabla `FileSystem` para cada fichero o directorio, la cual puede contener varios `FileChunk` indexados en la columna embedding de tipo Vector. Además, cada *chunk* puede referenciar o ser referenciado por otros *chunk*, en caso de que el chunk referenciado contenga una clase o función definida en el chunk referenciador. La tabla `Ancestor` constituye un patrón de tabla de cierre para acceder eficientemente a todos los ficheros dentro de un subdirectorio.

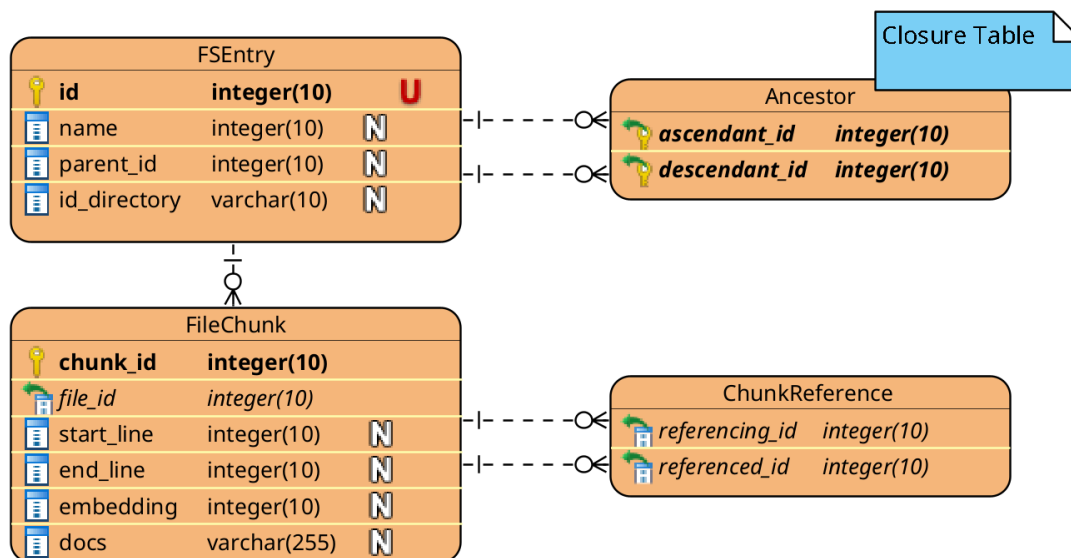


Figura 6.2: Diagrama relacional de la base de datos con el código fuente del proyecto software

División de los segmentos de código Para realizar la división de los ficheros en *chunks*, se han considerado las clases y funciones que componen el código.

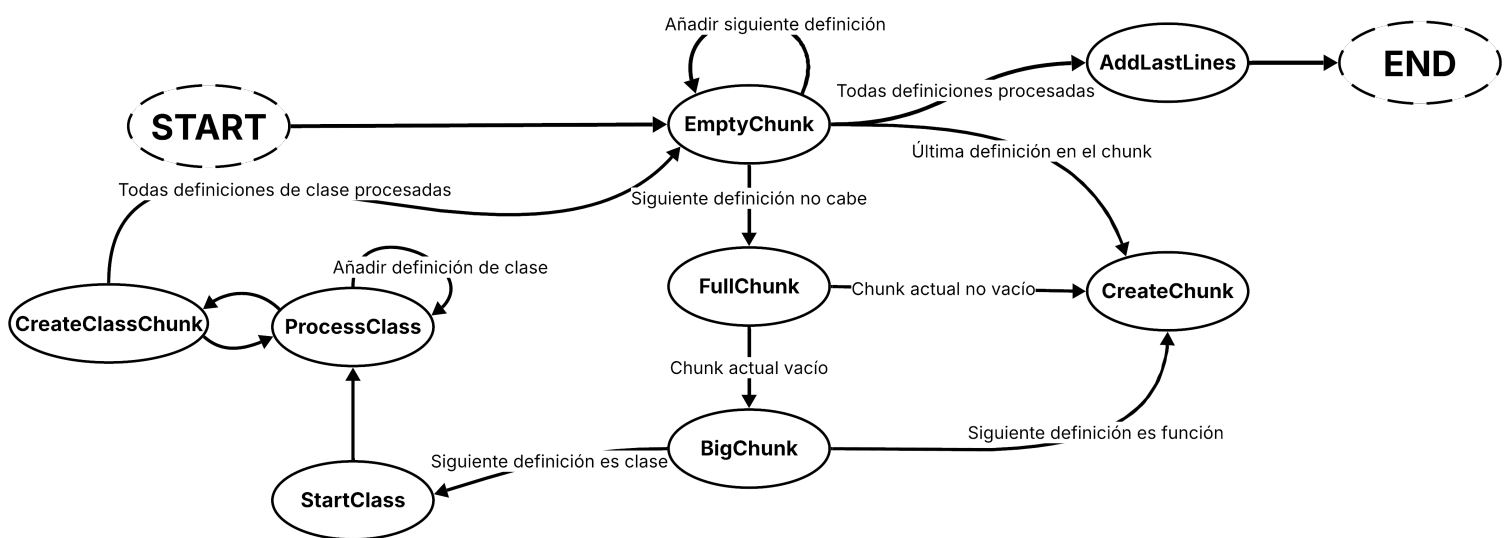


Figura 6.3: Algoritmo de chunking considerando definiciones de funciones y clases en el código fuente

Definición de términos técnicos

A.1. Conjunto de datos etiquetados

Un conjunto de datos etiquetado es una colección estructurada de información donde cada elemento o instancia está asociado a una o más categorías, clases o valores objetivo, denominados etiquetas. Estas etiquetas representan la información que se desea predecir o clasificar mediante un modelo de aprendizaje automático.

En el contexto del aprendizaje supervisado, estos conjuntos constituyen la base para el entrenamiento de modelos, ya que proporcionan ejemplos concretos de la relación entrada-salida que el algoritmo debe aprender a generalizar.

A.2. Entrenamiento de redes neuronales

El entrenamiento de una red neuronal consiste en un proceso iterativo de modificación de los pesos de las conexiones entre neuronas artificiales. Estos ajustes permiten que la red aprenda a generalizar a partir de los datos de entrenamiento, extrayendo patrones subyacentes que podrá aplicar posteriormente a datos no observados.

En el aprendizaje supervisado, específicamente durante el ajuste fino, los pesos se modifican comparando las predicciones del modelo con los datos de referencia. Esta comparación se cuantifica mediante una función de pérdida, cuyos gradientes, calculados mediante la regla de la cadena, indican cómo deben ajustarse los pesos para minimizar el error. Este mecanismo de retropropagación permite que la red optimice progresivamente su capacidad predictiva.

A.3. Distancia coseno

La distancia coseno es una medida que cuantifica la similitud entre dos vectores basándose en el coseno del ángulo que forman, independientemente de sus magnitudes. Matemáticamente se expresa como:

$$Similitud_{coseno}(x, y) = \frac{x \cdot y}{|x||y|}$$

El valor 1 indica vectores perfectamente alineados (máxima similitud), 0 representa vectores perpendiculares (sin similitud) y -1 señala vectores en direcciones opuestas (máxima disimilitud).

A.4. Tokenizador

Un tokenizador es el componente algorítmico encargado de segmentar el texto en unidades mínimas procesables (tokens), implementando reglas específicas de división basadas en espacios, puntuación, subpalabras o patrones predefinidos según el modelo de lenguaje.

Elicitación de preguntas

Los índices numéricos han sido establecidos en base a una captura de datos que fue inicialmente ampliada y posteriormente sometida a un proceso de depuración manual, con el objetivo de incorporar exclusivamente preguntas no redundantes.

La presencia del carácter “e” en el índice denota preguntas de carácter específico vinculadas a ejemplos concretos, esto es, aquellas que precisan de un contexto adicional para su adecuada interpretación. Las preguntas identificadas con el carácter “a” en su índice corresponden a interrogantes anotadas directamente del cuestionario electrónico, preservando su formulación original sin ningún tipo de alteración.

Listing B.1: Listado de elicitación de preguntas procesadas y clasificadas

```
1 {  
2   "informacion_general": {  
3     "intencion_del_proyecto": {  
4       "1": "¿Cuál es el objetivo principal y la finalidad del proyecto?",  
5       "2": "¿Qué problema específico o necesidad resuelve este proyecto?"  
6     },  
7     "funcionalidades_del_proyecto": {  
8       "3": "¿Cuáles son las funcionalidades principales que incluye el  
9       proyecto?",  
10      "4": "¿Qué funcionalidades están explícitamente fuera del alcance del  
11      proyecto?"  
12    },  
13    "estructura_del_proyecto": {  
14      "5": "¿Cuál es la estructura organizativa general del proyecto a nivel  
15      de repositorios o subproyectos?",
```

```
13     "79a": "¿Cómo están organizados los módulos, componentes y paquetes
14     dentro del proyecto?"
15 },
16     "contexto_de_negocio": {
17         "6": "¿Cuáles son los requisitos funcionales detallados del proyecto?",
18         "7": "¿Cuáles son los requisitos no funcionales (rendimiento, seguridad,
19         escalabilidad, etc.) del proyecto?",
20         "8": "¿Existe documentación formal del modelo de negocio o dominio? ¿Dó
21         nde se encuentra?",
22         "80ae": "¿Dónde puedo encontrar los requerimientos funcionales
23         documentados para entender el problema a resolver?"
24     },
25     "repositorio_codigo": {
26         "140a": "¿Cuál es la URL completa del repositorio de código y cómo puedo
27         acceder a él?"
28     }
29 },
30     "entorno_y_despliegue": {
31         "guias_existentes": {
32             "9": "¿Existen guías o manuales de despliegue para el proyecto? ¿Dónde
33             puedo encontrarlas?"
34         },
35         "entornos_disponibles": {
36             "10a": "¿Qué entornos están configurados o están disponibles para el
37             proyecto (desarrollo, pruebas, preproducción, producción, etc.)?",
38             "11a": "¿Qué credenciales o permisos necesito para acceder a cada
39             entorno (VPN, usuarios, certificados, etc.)?"
40         },
41         "configuracion_entorno_desarrollo": {
42             "12": "¿Cuál es el proceso paso a paso para configurar mi entorno de
43             desarrollo local (IDE, herramientas, plugins)?",
44             "13a": "¿Cómo compilo y ejecuto el proyecto en mi entorno local? ¿Qué
45             comandos debo utilizar?",
46             "84a": "¿Qué IDE o editor es recomendado para este proyecto y qué
47             configuraciones específicas requiere?",
48             "85a": "¿Cómo configuro mi entorno de desarrollo para integrarlo con los
49             sistemas corporativos?",
50             "86a": "¿Cuál es el proceso completo para compilar el proyecto y
51             verificar que funciona correctamente?"
52         },
53         "despliegue": {
```

```

41   "14": "¿Qué sistema o plataforma se utiliza para el despliegue de
    aplicaciones?",
42   "15": "¿Cuál es el proceso detallado de despliegue, incluyendo
    configuraciones, tecnologías y herramientas utilizadas?",
43   "87a": "¿Existen pipelines DevOps implementados para la compilación y
    despliegue en los diferentes entornos?"
44   }
45 },
46 "gestion_del_proyecto": {
47   "equipo_comunicacion_coordinacion": {
48     "comunicacion": {
49       "16": "¿Cuáles son los canales oficiales de comunicación del equipo (
    chat, email, videollamadas)?",
50       "17": "¿Cómo puedo contactar a cada miembro del equipo y cuál es su
    rol o área de responsabilidad?"
51     },
52     "roles": {
53       "18": "¿Quién es el líder del proyecto o responsable final de las
    decisiones?",
54       "19": "¿Quiénes son los responsables de cada subsistema o área del
    proyecto y cuáles son sus responsabilidades específicas?"
55     },
56     "reuniones_ceremonias": {
57       "21": "¿Qué reuniones periódicas o ceremonias están establecidas en el
    proyecto y cuál es su propósito?",
58       "88a": "¿Con qué frecuencia se realizan reuniones de equipo o
    seguimiento del proyecto?",
59       "89a": "¿Cuál es la periodicidad de las reuniones (diarias, semanales,
    etc.) y su duración estimada?",
60       "90a": "¿Cuáles son los objetivos y entregables esperados para cada
    tipo de reunión?"
61     }
62   },
63   "metodologia_contribucion": {
64     "23": "¿Dónde puedo encontrar las guías oficiales de contribución al
    proyecto?",
65     "24": "¿Cuál es el proceso completo para contribuir código al proyecto,
    desde la asignación hasta la integración?",
66     "25": "¿Existen tareas marcadas como 'good first issues' para nuevos
    contribuyentes? ¿Dónde puedo encontrarlas?",
67     "91a": "¿Cuál es el procedimiento detallado para entregar una tarea

```

```

completada (revisión, validación, merge)?"
68 },
69 "gestion_tareas_requisitos": {
70   "sistema_gestion_tareas": {
71     "26": "¿Qué herramienta específica se utiliza para gestionar las
tareas del proyecto (Jira, Trello, GitHub Projects, etc.)?",
72     "27": "¿En qué ubicación exacta dentro del sistema de gestión están
descritas las tareas pendientes?",
73     "28": "¿Cómo se identifican y clasifican las tareas por prioridad o
urgencia?",
74     "92a": "¿Qué herramienta de gestión de tareas se utiliza en el
proyecto y cómo accedo a ella?",
75     "93a": "¿Dónde puedo encontrar la descripción detallada de las tareas
asignadas o disponibles?",
76     "94ae": "¿Qué tareas específicas tengo asignadas actualmente o debo
realizar?",
77     "95a": "¿Cómo puedo identificar cuáles son las tareas más urgentes o
prioritarias en este momento?"
78   },
79   "gestion_requisitos": {
80     "29": "¿En qué sistema o plataforma se documentan y gestionan los
requisitos del proyecto?",
81     "30": "¿Cuál es el proceso establecido para analizar, validar y
aprobar nuevos requisitos?",
82     "96a": "¿Dónde están registrados formalmente los requisitos del
proyecto (Jira, Confluence, documentos, hojas de cálculo)?"
83   }
84 },
85 "informacion_cliente": {
86   "97a": "¿Quién es el cliente final o usuario principal de esta aplicació
n y cuál es su contexto de uso?",
87   "98a": "¿Qué nivel de participación tiene el cliente en el proceso de
desarrollo y toma de decisiones?",
88   "99ae": "¿Es necesario consultar directamente al cliente para resolver
dudas sobre determinadas funcionalidades o requisitos?"
89 }
90 },
91 "estandares_y_practicas": {
92   "estandares_nomenclatura_organizacion": {
93     "33": "¿Cuáles son los estándares definidos para la nomenclatura y gesti
ón de branches, commits y pull requests?",

```

```

94     "34": "¿Cuál es el proceso completo para entregar una tarea, desde su
    finalización hasta la aprobación?",
95     "100a": "¿Existe un estándar documentado para la nomenclatura de
    branches, commits y otros elementos del repositorio?"
96 },
97     "estandares_codigo": {
98         "35": "¿Para qué lenguajes de programación existen estándares de
    codificación definidos en el proyecto?",
99         "101a": "¿Se utiliza alguna guía de estilo o formato de código especí
    fico para cada lenguaje del proyecto?",
100        "102a": "¿Existe una estructura o arquitectura de código predefinida que
    deba seguirse?"
101    },
102    "estandares_diseno": {
103        "36": "¿Existe un sistema de diseño o guía de estilos para la interfaz
    de usuario?",
104        "103a": "¿Hay diseños en Figma u otra herramienta para las nuevas
    pantallas o componentes a desarrollar?",
105        "104a": "¿Dónde puedo encontrar la documentación sobre el diseño visual
    y la experiencia de usuario a implementar?",
106        "106a": "¿Cuál es el procedimiento a seguir si no existen diseños
    definidos para un componente o pantalla?"
107    },
108    "practicas": {
109        "ci_cd": {
110            "37": "¿Qué procesos de Integración Continua y Despliegue Continuo (CI
    /CD) están implementados?",
111            "107a": "¿Cuál es el flujo completo de integración continua, desde el
    commit hasta la validación?",
112            "108a": "¿Qué herramientas específicas se utilizan para los procesos
    de integración y despliegue continuo?"
113        },
114        "ci": {
115            "38": "¿Cómo funciona detalladamente el proceso de integración
    continua y qué validaciones incluye?"
116        },
117        "cd": {
118            "39": "¿Cómo se ejecuta el proceso de despliegue continuo y qué
    entornos abarca?"
119        }
120    },

```

```
121 "aspectos_legales": {
122     "40": "¿Qué licencias de software se utilizan en el proyecto y sus
dependencias?",
123     "41": "¿Cuáles son las consideraciones legales específicas que deben
tenerse en cuenta durante el desarrollo?",
124     "110a": "¿Cuál es el protocolo para gestionar adecuadamente las
licencias de componentes externos?"
125 },
126 "estandares_seguridad": {
127     "42": "¿Qué herramientas o procesos se utilizan para identificar
vulnerabilidades de seguridad en el código?",
128     "44": "¿Cómo se gestionan y auditan las dependencias desde la
perspectiva de seguridad?",
129     "112a": "¿Cómo verifico que las dependencias externas que utilizo son
seguras y se mantienen actualizadas?",
130     "113a": "¿Cuál es el procedimiento a seguir si descubro una
vulnerabilidad crítica en una dependencia?",
131     "114a": "¿Cuáles son las mejores prácticas de seguridad establecidas que
debo aplicar en mi código para este proyecto?"
132 },
133 "pruebas_calidad": {
134     "45": "¿Qué tipos de pruebas se realizan en el proyecto (unitarias,
funcionales, integración, rendimiento)?",
135     "46": "¿Cuál es la política establecida para la ejecución de pruebas (
por commit, por merge request, al final del sprint)?",
136     "47a": "¿Cómo se automatizan las pruebas y qué herramientas y tecnologí
as se utilizan para ello?",
137     "48": "¿Cuál es el porcentaje actual de cobertura de pruebas y cuál es
el objetivo establecido?",
138     "115a": "¿Existen pruebas unitarias implementadas para el código actual?
¿Dónde se encuentran?",
139     "116a": "¿Qué clases o métodos tienen pruebas unitarias documentadas y
cuáles necesitan implementación?"
140 }
141 },
142 "documentacion": {
143     "49a": "¿Qué fuentes de documentación existen para el proyecto y dónde
puedo encontrarlas (API, guías, licencias, estándares)?",
144     "50": "¿Cuál es la estructura organizativa de la documentación del
proyecto?",
145     "51e": "¿Qué documentación específica debo consultar para realizar esta
```



```

146     tarea concreta?",
147     "52": "¿Cuál es el proceso para modificar o actualizar la documentación
del proyecto?",
148     "53": "¿Cuál es el procedimiento establecido para documentar cambios en el
código?",
149     "118a": "¿Existe un espacio de documentación centralizado como Confluence
para el proyecto?",
150     "120a": "¿Es obligatorio documentar los cambios realizados en el código? ¿
Qué nivel de detalle se requiere?"
151 },
152 "recursos_adicionales": {
153     "54e": "¿Existen preguntas frecuentes o discusiones en StackOverflow
relacionadas con este tema o tecnología?",
154     "124ae": "¿Dónde puedo encontrar la documentación técnica actualizada para
las tecnologías o herramientas específicas que necesito utilizar?",
155     "123a": "¿Qué herramientas o utilidades podrían ayudarme a ejecutar mis
tareas de manera más eficiente?",
156     "formaciones": {
157         "55e": "¿Qué recursos formativos están disponibles sobre estas tecnologí
as y cuáles son más relevantes para mi tarea actual?",
158         "122ae": "¿Dónde puedo encontrar material de formación específico para
las tecnologías utilizadas en este proyecto?"
159     }
160 },
161 "arquitectura_del_sistema": {
162     "tecnologias_y_plataformas": {
163         "stack_tecnologico": {
164             "56a": "¿Cuáles son todas las tecnologías, frameworks y lenguajes
utilizados en el proyecto?",
165             "57": "¿Para qué componente o funcionalidad específica se utiliza cada
tecnología del proyecto?",
166             "129a": "¿Qué herramientas específicas se utilizan para gestionar las
migraciones de esquemas de base de datos?"
167         },
168         "plataformas_disponibles": {
169             "58": "¿Qué plataformas o herramientas de soporte están disponibles
para el proyecto (diseño, colaboración, monitoreo)?"
170         }
171     },
172     "dependencias": {
173         "126a": "¿Qué herramientas o procesos se utilizan para gestionar las

```



```

201     "evaluacion_y_mejora": {
202         "138a": "¿El enfoque de desarrollo actual es óptimo o existen
oportunidades de mejora identificadas?",
203         "139a": "¿Cuál sería el costo en tiempo y recursos para optimizar el
proceso de desarrollo actual?"
204     }
205 },
206     "nivel_3_diagrama_componentes": {
207         "72": "¿Cuáles son los componentes internos de cada contenedor y cuál
es la función específica de cada uno?",
208         "131a": "¿Cuál es la arquitectura de integración entre los
diferentes servicios o componentes del sistema?",
209         "comunicacion_entre_componentes": {
210             "73e": "¿Qué patrones o protocolos de comunicación se utilizan
entre los componentes dentro de un mismo contenedor?"
211         },
212         "dependencias_entre_componentes": {
213             "74": "¿Cómo se gestionan las dependencias y el ciclo de vida
entre los componentes de diferentes contenedores?"
214         },
215         "tecnologias": {
216             "71": "¿Qué tecnologías, frameworks o bibliotecas específicas
utiliza cada componente?"
217         }
218     },
219     "nivel_4_diagrama_codigo": {
220         "estructura_diagrama_clases": {
221             "75e": "¿Cuál es la estructura detallada de clases, interfaces y
objetos dentro de un componente específico?",
222             "76e": "¿Cuál es la responsabilidad y función principal de cada
clase o interfaz dentro del componente?",
223             "132ae": "¿Puedes proporcionar un diagrama de paquetes y clases para
entender la estructura del código?",
224             "133ae": "¿Puedes mostrarme la jerarquía completa de llamadas para
este método específico?",
225             "134ae": "¿Cuáles son los métodos más complejos o difíciles de
entender en el código y por qué?"
226         },
227         "patrones_diseno": {
228             "77": "¿Qué patrones de diseño, estructuras de herencia o composició
n se implementan en el código?",

```

```
229     "135a": "¿Qué patrones arquitectónicos o de diseño se utilizan en el  
    proyecto (MVC, MVVM, etc.)?",  
230     "136ae": "¿Por qué se eligieron estos patrones arquitectónicos o de  
    diseño específicos?",  
231     "137ae": "¿Qué arquitectura o patrones debo implementar para mi  
    desarrollo actual?"  
232 },  
233     "principios_diseno": {  
234         "78": "¿Qué principios de diseño (SOLID, DRY) o buenas prácticas de  
    código se aplican en el proyecto?"  
235     }  
236 }  
237 }  
238 }  
239 }
```

Actas de reuniones

A.1. Acta de reunión TFG (25/02/2025)

Fecha: 25/02/2025

Inicio de reunión: 14:00

Fin de reunión: 16:00

Lugar: Sala Zurriola

Tipo de reunión: Iniciación

Asistentes:

Maiden Azanza
Aritz Galdos
Martín López de Ipiña
Beatriz Pérez Lamanha
Nerea Larrañaga
Jon Dorronsoro

A.1.1. Orden del día

1. Presentar el estado actual del proyecto Onboarding en LKS
2. Sesión de Brainstorming para el TFG

A.1.2. Resumen de la reunión

Se ha comenzado con una presentación del trabajo de Nerea en el proyecto de Onboarding en LKS. Se ha comentado la disponibilidad de una base de datos de itinerarios personalizados para el proceso de Onboarding.

Después, Aritz ha presentado sus requisitos para el TFG; una exploración de la implementación técnica de agentes LLM, para la posterior implementación en otros proyectos. A continuación, se ha procedido a una sesión de Brainstorming, donde las ideas destacadas son:

- Asistente ChatBot para la integración Onboarding en proyectos software. Se enfocaría en resolver cuestiones de dominio, arquitectura o prácticas software. Se descarta la generación de código dada su complejidad y la diversidad de herramientas existentes.
- Generador de ejercicios para formaciones de Onboarding usando agentes LLM.

La principal inquietud radica en la gestión del alcance y la validación del sistema. Se ha mencionado el riesgo de proponer un proyecto demasiado ambicioso, resultando en fracaso por falta de recursos.

A.1.3. Estado del proyecto

El proyecto se encuentra en una fase inicial, el alcance no está definido.

A.1.4. Decisiones

A.1.4.1. Decisiones adoptadas

Dedicar un primer sprint para definir los requisitos y alcance del proyecto.

A.1.4.2. Asignación de tareas a realizar

Tarea	Responsable	Fecha límite
Realizar una propuesta de alcance del proyecto	Martín	12/03/25
Diseñar una propuesta de diseño para el sistema de agentes LLM	Martín	12/03/25

Tabla C.1: Tareas asignadas (25/02/2025)

Próxima reunión: 12/03/2025

A.2. Acta de reunión TFG (12/03/2025)

Fecha: 12/03/2025

Inicio de reunión: 14:00

Fin de reunión: 14:45

Lugar: Telemático

Tipo de reunión: Seguimiento

Asistentes:

Maider Azanza

Aritz Galdos

Martín López de Ipiña

Juanan Pereira

A.2.1. Orden del día

1. Presentar frameworks de agentes y caso de uso propuesto
2. Decidir el caso de uso

A.2.2. Resumen de la reunión

Se ha comenzado con una presentación de Martín de los Frameworks orientados a agentes y su caso de uso propuesto para la aplicación. Se ha propuesto orientarlo a la conexión entre el proyecto software y una formación proporcionado por la empresa, creando ejercicios específicos de la documentación y proyecto de la empresa. Tras esto, se ha comentado que la creación de ejercicios por agentes LLM ya ha sido ampliamente investigada.

Juanan ha aclarado que la parte interesante radica en vincular el usuario con los diferentes recursos de la empresa; proyecto software, guía de estilo y código, documentación del proyecto... También se ha mencionado la necesidad de generar datos para los casos en los que se va a utilizar el sistema.

Se han comentado varias ideas técnicas para el sistema de agentes:

- Un procesamiento del prompt del usuario para la aclaración de la tarea a realizar. Se puede complementar con el patrón human-in-the-loop para capturar mejor la intención del usuario, similar a deepresearch.
- División del sistema de agentes por especialistas. Cada uno tendría acceso a herramientas especializadas en un dominio, pudiendo ser las herramientas otro agente.

- Módulo de memoria para guardar la información relacionada con el usuario y sus conversaciones pasadas.
- Interacción entre los diferentes agentes especialistas. Podría ser mediante una conversación entre agentes, cada uno proponiendo su propuesta específica. También es posible un tablón de tareas, donde cada agente leería las cuestiones asignadas a su etiqueta.
- Planificación a alto y bajo nivel. Primero un agente compondría las ideas generales, mientras que otro definiría más concretamente qué pasos llevar a cabo. Un sistema de feedback para la planificación convendría también.

A.2.3. Estado del proyecto

El proyecto tiene un alcance más definido, pero todavía no se tiene captura de requisitos.

A.2.4. Decisiones

A.2.4.1. Decisiones adoptadas

Dedicar una semana más a la búsqueda del caso de uso específico. Buscar recursos disponibles en la empresa para el desarrollo del proyecto. Considerar varios frameworks a la hora del desarrollo. Se debe tener en cuenta el nuevo framework de OpenAI, langflow.

A.2.4.2. Asignación de tareas a realizar

Tarea	Responsable	Fecha límite
Proponer diferentes casos de uso específicos para el sistema de agentes	Martín	20/03/25
Definir los recursos disponibles en la empresa para el desarrollo del proyecto	Aritz	20/03/25

Tabla C.2: Tareas asignadas (12/03/2025)

Próxima reunión: 20/03/2025

A.3. Acta de reunión TFG (20/03/2025)

Fecha: 20/03/2025

Inicio de reunión: 12:30

Fin de reunión: 13:10

Lugar: Telemático

Tipo de reunión: Seguimiento

Asistentes:

Maider Azanza
Aritz Galdos
Juanan Pereira
Martín López de Ipiña

A.3.1. Orden del día

1. Presentar casos de uso propuestos
2. Decidir el caso de uso

A.3.2. Resumen de la reunión

Se ha comenzado con una presentación de Martín de los casos de uso propuestos para el agente. Se han propuesto 5 posibles preguntas para el sistema: información general del proyecto, gestión del proyecto, preguntas relacionadas sobre la documentación, preguntas sobre formaciones adicionales y arquitectura del proyecto. Martín ha propuesto enfocar el agente únicamente en la arquitectura del proyecto e información general del proyecto. También ha propuesto varios posibles proyectos open source donde aplicar el sistema dada la falta de documentación en los proyectos open source de la empresa.

Posteriormente, Juanan ha propuesto no descartar los demás casos de uso, y añadirlos con un enfoque iterativo incremental. También se ha decidido buscar más proyectos disponibles en la empresa, y generar la documentación faltante con LLMs.

A.3.3. Estado del proyecto

El alcance general del proyecto está definido, los requisitos generales están definidos.

A.3.4. Decisiones**A.3.4.1. Decisiones adoptadas**

Refinar los diferentes tipos de preguntas en una taxonomía para poder definir un proceso iterativo. Buscar más proyectos disponibles en la empresa para el desarrollo del sistema.

A.3.4.2. Asignación de tareas a realizar

Tarea	Responsable	Fecha límite
Crear la taxonomía de preguntas	Martín	02/04/2025
Buscar proyectos software disponibles en la empresa para la aplicación del sistema de agentes	Aritz	02/04/2025

Tabla C.3: Tareas asignadas (20/03/2025)

Próxima reunión: 02/04/2025

A.4. Acta de reunión TFG (02/04/2025)

Fecha: 02/04/2025

Inicio de reunión: 14:00

Fin de reunión: 14:45

Lugar: Telemático

Tipo de reunión: Seguimiento

Asistentes:

Maider Azanza

Aritz Galdos

Juanan Pereira

Martín López de Ipiña

A.4.1. Orden del día

1. Presentar taxonomía generada con el mailing
2. Presentar proyecto IA-core-tools propuesto
3. Presentar agente de código propuesto e implementación actual

A.4.2. Resumen de la reunión

Se ha comenzado con una presentación de Martín sobre la taxonomía de preguntas anotadas, el proyecto IA-core-tools y el agente de código propuesto. A continuación, Aritz ha expuesto que la idea es tener un sistema mínimo implementado, para posteriormente ir añadiendo agentes y mejoras de estos.

Se ha comentado la utilidad de realizar una pequeña investigación antes de crear cada agente. Podría ser más interesante incorporar uno ya implementado al sistema y evaluar su rendimiento.

Tras esto, Juanan ha comentado la posibilidad de utilizar búsquedas por expresiones regulares o palabras clave de forma complementaria a la búsqueda semántica.

A.4.3. Estado del proyecto

El primer sprint está casi finalizado, el agente de código está en proceso de implementación.

A.4.4. Decisiones

A.4.4.1. Decisiones adoptadas

Crear una implementación del sistema mínimo con el agente de código para el siguiente sprint. Dedicar algo de tiempo a buscar implementaciones ya existentes de agentes antes de implementarlos. Utilizar Jira para la gestión del proyecto.

A.4.4.2. Asignación de tareas a realizar

Tarea	Responsable	Fecha límite
Acabar la implementación del agente de código	Martín	15/04/2025
Crear una planificación en Jira con los issues y sprints	Martín	15/04/2025

Tabla C.4: Tareas asignadas (02/04/2025)

Próxima reunión: 15/04/2025

A.5. Acta de reunión TFG (04/04/2025)

Fecha: 04/04/2025

Inicio de reunión: 12:00

Fin de reunión: 12:30

Lugar: Telemático

Tipo de reunión: Captura de recursos

Asistentes:

Aritz Galdos

Martín López de Ipiña

Juan Carlos del Valle

Uxue Reino

A.5.1. Orden del día

1. Explicar el funcionamiento del equipo de diseño de interfaces de usuario en LKS
2. Exponer la idea del TFM de Uxue

A.5.2. Resumen de la reunión

Se ha comenzado con una breve explicación del TFG de Martín. Se han explicado los documentos que podrían ser de utilidad: guías de estilo, documentación de proceso, etc.

A continuación, Juan Carlos ha explicado el proceso general en su departamento. Se parte del requisito de un cliente, para lo que se crea un diseño con herramientas como figma. El diseño se exporta posteriormente a una maqueta en HTML, para lo que el equipo de desarrollo puede utilizar como base a seguir. En función del cliente se siguen ciertos estándares de documentación, por ejemplo, para Orona el proceso se documenta en un Confluence.

Finalmente, Uxue ha hecho una breve explicación del objetivo de su TFM. La idea es eliminar por completo las maquetas HTML y generar una base directamente en el framework frontend utilizado.

A.5.3. Decisiones

A.5.3.1. Decisiones adoptadas

Aprovechar los documentos compartidos por Juan Carlos y Uxue para generar la documentación del agente correspondiente. Definir un agente con acceso a Confluence como uno de los posibles agentes a implementar.

A.5.3.2. Asignación de tareas a realizar

Tarea	Responsable	Fecha límite
Incluir los recursos compartidos en la documentación disponible para los agentes	Martín	-

Tabla C.5: Tareas asignadas (04/04/2025)

A.6. Acta de reunión TFG (15/04/2025)

Fecha: 15/04/2025

Inicio de reunión: 10:30

Fin de reunión: 11:30

Lugar: Telemático

Tipo de reunión: Seguimiento

Asistentes:

Maider Azanza

Aritz Galdos

Juanan Pereira

Martín López de Ipiña

A.6.1. Orden del día

1. Presentar Sistema mínimo de agentes actual
2. Proponer siguiente iteración como evaluación y mejora del sistema mínimo

A.6.2. Resumen de la reunión

Se ha comenzado con una presentación de Martín sobre el sistema mínimo implementado actual. Contiene 5 agentes especializados, un orquestador, un planificador y un formateador de la respuesta. Se ha hecho una demostración del funcionamiento y se han comentado algunos detalles de implementación.

Martín ha comentado la necesidad de evaluar el sistema antes de implementar mejoras, para poder evaluar si las mejoras posteriores realmente mejoran el sistema. Aritz ha ofrecido el TFG de Mikel Lonbide como ayuda para la implementación, ya que este desarrolló un benchmark para la evaluación de modelos LLM.

Se ha propuesto que el agente formateador contenga la capacidad de citar las fuentes de su respuesta.

Aritz ha comentado que le gustaría probar un agente orquestador con la capacidad incorporada de pensamiento propio. Se ha decidido incluir esta posibilidad en las mejoras del sistema actual tras implementar el evaluador del sistema.

A.6.3. Estado del proyecto

La segunda iteración está finalizada, se debe empezar con la tercera.

A.6.4. Decisiones

A.6.4.1. Decisiones adoptadas

Crear un sistema de evaluación tanto para los agentes individuales como para el sistema completo. Se deben considerar dos métricas:

- Las llamadas a las herramientas son las adecuadas.
- La respuesta del agente contiene los puntos a incluir en los datos anotados.

Incluir una herramienta de referencias en el agente formateador. Incluir un orquestador con capacidad de decisión razonada en la fase de mejoras.

A.6.4.2. Asignación de tareas a realizar

Tarea	Responsable	Fecha límite
Empezar con la siguiente iteración para evaluar y mejorar los agentes actuales	Martín	28/04/2025

Tabla C.6: Tareas asignadas (15/04/2025)

Próxima reunión: 28/04/2025

A.7. Acta de reunión TFG (29/04/2025)

Fecha: 29/04/2025

Inicio de reunión: 10:30

Fin de reunión: 11:30

Lugar: Telemático

Tipo de reunión: Seguimiento

Asistentes:

Maider Azanza

Aritz Galdos

Juanan Pereira

Martín López de Ipiña

A.7.1. Orden del día

1. Presentar el sistema de evaluación y las mejoras implementadas
2. Decidir el enfoque del proyecto para la siguiente evaluación

A.7.2. Resumen de la reunión

Se ha comenzado con una presentación de Martín del trabajo realizado, explicado el sistema de evaluación, los resultados de las evaluaciones realizadas y las mejoras implementadas. Se han explicado las mejoras del sistema de citas, los prompts de los agentes orquestadores y planificadores y la optimización del costo de los agentes especializados. También se han definido las variaciones de orquestación posibles por implementar.

Tras esto, Aritz ha indicado especial interés en las variaciones de orquestación, ya que como su evaluación está automatizada su implementación es en un principio trivial.

Respecto a la iteración de mejora de interacción de agentes, se ha comentado la problemática de que un sistema de memoria sobre ejecuciones anteriores limitaría el conocimiento del agente al momento de su registro. Para evitar esto, Juanan ha indicado que se pueden utilizar sistemas de actualización de información periódicas.

La reunión ha finalizado con la decisión del enfoque del rumbo del proyecto. La dedicación horaria ha sido mayor de lo inicialmente planificada, por lo que es necesario ajustar algunas iteraciones. La complejidad técnica del proyecto es un principio suficiente, por lo que se ha decidido reducir en gran medida la dedicación horaria de las últimas dos iteraciones y centrar el enfoque en la redacción de la memoria.

A.7.3. Estado del proyecto

La tercera iteración ha finalizado, la cuarta iteración se encuentra aproximadamente por la mitad.

A.7.4. Decisiones

A.7.4.1. Decisiones adoptadas

- Reducir la dedicación horaria en lo relacionado a la implementación técnica en las últimas dos iteraciones.
- Centrar los esfuerzos en la redacción de la memoria.

A.7.4.2. Asignación de tareas a realizar

Tarea	Responsable	Fecha límite
Crear un índice de todos los capítulos a incluir en la memoria	Martín	4/05/2025
Acabar las mejoras y los sistemas de orquestación	Martín	9/05/2025

Tabla C.7: Tareas asignadas (29/04/2025)

Próxima reunión: 9/05/2025

Bibliografía

- [1] S.E. Sim and R.C. Holt. The ramp-up problem in software projects: a case study of how software immigrants naturalize. In *Proceedings of the 20th International Conference on Software Engineering*, pages 361–370. ISSN: 0270-5257. URL: <https://ieeexplore.ieee.org/abstract/document/671389>. Ver página 3.
- [2] Igor Steinmacher, Marco Aurelio Graciotto Silva, Marco Aurelio Gerosa, and David F. Redmiles. A systematic literature review on the barriers faced by newcomers to open source software projects. 59:67–85. URL: <https://www.sciencedirect.com/science/article/pii/S0950584914002390>. Ver página 3.
- [3] Eva Ritz, Fabio Donisi, Edona Elshan, and Roman Rietsche. Artificial socialization? how artificial intelligence applications can shape a new era of employee onboarding practices. URL: <http://hdl.handle.net/10125/102648>. Ver página 4.
- [4] Maider Azanza, Juanan Pereira, Arantza Irastorza, and Aritz Galdos. Can LLMs facilitate onboarding software developers? an ongoing industrial case study. In *2024 36th International Conference on Software Engineering Education and Training (CSEE&T)*, pages 1–6. ISSN: 2377-570X. URL: <https://ieeexplore.ieee.org/document/10662989>. Ver página 4.
- [5] Andrei Cristian Ionescu, Sergey Titov, and Maliheh Izadi. A multi-agent onboarding assistant based on large language models, retrieval augmented generation, and chain-of-thought. URL: <http://arxiv.org/abs/2503.23421>. Ver página 4.
- [6] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. Attention is all you need. URL: <http://arxiv.org/abs/1706.03762>. Ver página 4.
- [7] Shunyu Yao, Jeffrey Zhao, Dian Yu, Nan Du, Izhak Shafran, Karthik Narasimhan, and Yuan Cao. ReAct: Synergizing reasoning and acting in language models. URL: <http://arxiv.org/abs/2210.03629>. Ver página 6.
- [8] Model context protocol (MCP). URL: <https://docs.anthropic.com/en/docs/agents-and-tools/mcp>. Ver página 7.
- [9] Fengbin Zhu, Wenqiang Lei, Chao Wang, Jianming Zheng, Soujanya Poria, and Tat-Seng Chua. Retrieving and reading: A comprehensive survey on open-domain question answering. URL: <http://arxiv.org/abs/2101.00774>. Ver página 10.
- [10] Yunfan Gao, Yun Xiong, Xinyu Gao, Kangxiang Jia, Jinliu Pan, Yuxi Bi, Yi Dai, Jiawei Sun, Meng Wang, and Haofen Wang. Retrieval-augmented generation for large language models: A survey. URL: <http://arxiv.org/abs/2312.10997>. Ver página 10.

- [11] Xinbei Ma, Yeyun Gong, Pengcheng He, Hai Zhao, and Nan Duan. Query rewriting for retrieval-augmented large language models. Ver página 10.
- [12] Yoav Levine, Itay Dalmedigos, Ori Ram, Yoel Zeldes, Daniel Jannai, Dor Muhlgay, Yoni Osin, Opher Lieber, Barak Lenz, Shai Shalev-Shwartz, Amnon Shashua, Kevin Leyton-Brown, and Yoav Shoham. Standing on the shoulders of giant frozen language models. URL: <http://arxiv.org/abs/2204.10019>. Ver página 10.
- [13] Omar Khattab, Christopher Potts, and Matei Zaharia. Relevance-guided supervision for OpenQA with ColBERT. URL: <http://arxiv.org/abs/2007.00814>. Ver página 10.
- [14] Omar Khattab, Keshav Santhanam, Xiang Lisa Li, David Hall, Percy Liang, Christopher Potts, and Matei Zaharia. Demonstrate-search-predict: Composing retrieval and language models for knowledge-intensive NLP. URL: <http://arxiv.org/abs/2212.14024>. Ver página 10.
- [15] Zhihong Shao, Yeyun Gong, Yelong Shen, Minlie Huang, Nan Duan, and Weizhu Chen. Enhancing retrieval-augmented large language models with iterative retrieval-generation synergy. In Houda Bouamor, Juan Pino, and Kalika Bali, editors, *Findings of the Association for Computational Linguistics: EMNLP 2023*, pages 9248–9274. Association for Computational Linguistics. URL: <https://aclanthology.org/2023.findings-emnlp.620/>. Ver página 10.
- [16] Peng Qi, Haejun Lee, Oghenetegiri "TG"Sido, and Christopher D. Manning. Answering open-domain questions of varying reasoning steps from text. URL: <http://arxiv.org/abs/2010.12527>. Ver página 10.
- [17] Huaixiu Steven Zheng, Swaroop Mishra, Xinyun Chen, Heng-Tze Cheng, Ed H. Chi, Quoc V. Le, and Denny Zhou. Take a step back: Evoking reasoning via abstraction in large language models. URL: <http://arxiv.org/abs/2310.06117>. Ver página 10.
- [18] Harsh Trivedi, Niranjan Balasubramanian, Tushar Khot, and Ashish Sabharwal. Interleaving retrieval with chain-of-thought reasoning for knowledge-intensive multi-step questions. URL: <http://arxiv.org/abs/2212.10509>. Ver página 10.
- [19] Lei Wang, Chen Ma, Xueyang Feng, Zeyu Zhang, Hao Yang, Jingsen Zhang, Zhiyuan Chen, Jiakai Tang, Xu Chen, Yankai Lin, Wayne Xin Zhao, Zhewei Wei, and Jirong Wen. A survey on large language model based autonomous agents. 18(6):186345. URL: <https://doi.org/10.1007/s11704-024-40231-1>. Ver páginas 10, 11.
- [20] Hongxin Zhang, Weihua Du, Jiaming Shan, Qinrong Zhou, Yilun Du, Joshua B. Tenenbaum, Tianmin Shu, and Chuang Gan. Building cooperative embodied agents modularly with large language models. URL: <http://arxiv.org/abs/2307.02485>. Ver página 10.
- [21] Kevin A. Fischer. Reflective linguistic programming (RLP): A stepping stone in socially-aware AGI (SocialAGI). URL: <http://arxiv.org/abs/2305.12647>. Ver página 10.
- [22] Xinnian Liang, Bing Wang, Hui Huang, Shuangzhi Wu, Peihao Wu, Lu Lu, Zejun Ma, and Zhoujun Li. *Unleashing Infinite-Length Input Capacity for Large-scale Language Models with Self-Controlled Memory System*. Ver páginas 10, 11.
- [23] Andrew Zhao, Daniel Huang, Quentin Xu, Matthieu Lin, Yong-Jin Liu, and Gao Huang. ExpeL: LLM agents are experiential learners. 38(17):19632–19642. Number: 17. URL: <https://ojs.aaai.org/index.php/AAAI/article/view/29936>. Ver página 10.

- [24] Wanjun Zhong, Lianghong Guo, Qiqi Gao, He Ye, and Yanlin Wang. MemoryBank: Enhancing large language models with long-term memory. 38(17):19724–19731. Number: 17. URL: <https://ojs.aaai.org/index.php/AAAI/article/view/29946>. Ver página 11.
- [25] Joon Sung Park, Joseph O’Brien, Carrie Jun Cai, Meredith Ringel Morris, Percy Liang, and Michael S. Bernstein. Generative agents: Interactive simulacra of human behavior. In *Proceedings of the 36th Annual ACM Symposium on User Interface Software and Technology*, pages 1–22. ACM. URL: <https://dl.acm.org/doi/10.1145/3586183.3606763>. Ver página 11.
- [26] Jason Wei, Xuezhi Wang, Dale Schuurmans, Maarten Bosma, Brian Ichter, Fei Xia, Ed Chi, Quoc Le, and Denny Zhou. Chain-of-thought prompting elicits reasoning in large language models. URL: <http://arxiv.org/abs/2201.11903>. Ver página 11.
- [27] Shunyu Yao, Dian Yu, Jeffrey Zhao, Izhak Shafran, Thomas L Griffiths, Yuan Cao, and Karthik Narasimhan. Tree of thoughts: Deliberate problem solving with large language models. Ver página 11.
- [28] Yancheng Wang, Ziyan Jiang, Zheng Chen, Fan Yang, Yingxue Zhou, Eunah Cho, Xing Fan, Xiaojian Huang, Yanbin Lu, and Yingzhen Yang. RecMind: Large language model powered agent for recommendation. URL: <http://arxiv.org/abs/2308.14296>. Ver página 11.
- [29] Noah Shinn, Federico Cassano, Ashwin Gopinath, Karthik Narasimhan, and Shunyu Yao. Reflexion: Language agents with verbal reinforcement learning. Ver página 11.
- [30] Aman Madaan, Niket Tandon, Prakhar Gupta, Skyler Hallinan, Luyu Gao, Sarah Wiegrefe, Uri Alon, Nouha Dziri, Shrimai Prabhumoye, Yiming Yang, Shashank Gupta, Bodhisattwa Prasad Majumder, Katherine Hermann, Sean Welleck, Amir Yazdanbakhsh, and Peter Clark. SELF-REFINE: Iterative refinement with self-feedback. Ver página 11.
- [31] Ning Miao, Yee Whye Teh, and Tom Rainforth. SelfCheck: Using LLMs to zero-shot check their own step-by-step reasoning. URL: <http://arxiv.org/abs/2308.00436>. Ver página 11.
- [32] Bill Yuchen Lin, Yicheng Fu, Karina Yang, Faeze Brahman, Shiyu Huang, Chandra Bhagavatula, Prithviraj Ammanabrolu, Yejin Choi, and Xiang Ren. SWIFTSAGE: A generative agent with fast and slow thinking for complex interactive tasks. Ver página 11.
- [33] Wenlong Huang, Pieter Abbeel, Deepak Pathak, and Igor Mordatch. Language models as zero-shot planners: Extracting actionable knowledge for embodied agents. Ver página 11.
- [34] Zihao Wang, Shaofei Cai, Guanzhou Chen, Anji Liu, Xiaojian Ma, and Yitao Liang. Describe, explain, plan and select: Interactive planning with large language models enables open-world multi-task agents. URL: <http://arxiv.org/abs/2302.01560>. Ver página 11.
- [35] Xizhou Zhu, Yuntao Chen, Hao Tian, Chenxin Tao, Weijie Su, Chenyu Yang, Gao Huang, Bin Li, Lewei Lu, Xiaogang Wang, Yu Qiao, Zhaoxiang Zhang, and Jifeng Dai. Ghost in the minecraft: Generally capable agents for open-world environments via large language models with text-based knowledge and memory. URL: <http://arxiv.org/abs/2305.17144>. Ver página 11.
- [36] Chan Hee Song, Brian M. Sadler, Jiaman Wu, Wei-Lun Chao, Clayton Washington, and Yu Su. LLM-planner: Few-shot grounded planning for embodied agents with large language models. In *2023 IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 2986–2997. IEEE. URL: <https://ieeexplore.ieee.org/document/10378628/>. Ver página 11.

- [37] Guanzhi Wang, Yuqi Xie, Yunfan Jiang, Ajay Mandlekar, Chaowei Xiao, Yuke Zhu, Linxi Fan, and Anima Anandkumar. Voyager: An open-ended embodied agent with large language models. URL: <http://arxiv.org/abs/2305.16291>. Ver página 11.
- [38] Shunyu Liu, Yaoru Li, Kongcheng Zhang, Zhenyu Cui, Wenkai Fang, Yuxuan Zheng, Tongya Zheng, and Mingli Song. Odyssey: Empowering minecraft agents with open-world skills. URL: <http://arxiv.org/abs/2407.15325>. Ver página 11.
- [39] Shreyas Sundara Raman, Vanya Cohen, Eric Rosen, Ifrah Idrees, David Paulius, and Stefanie Tellex. Planning with large language models via corrective re-prompting. Ver página 11.
- [40] LLM+p: Empowering large language models with optimal planning proficiency. URL: <http://arxiv.org/abs/2304.11477>. Ver página 11.
- [41] Gautier Dagan, Frank Keller, and Alex Lascarides. Dynamic planning with a LLM. URL: <http://arxiv.org/abs/2308.06391>. Ver página 11.
- [42] DeepSeek-r1/DeepSeek_r1.pdf at main · deepseek-ai/DeepSeek-r1. URL: https://github.com/deepseek-ai/DeepSeek-R1/blob/main/DeepSeek_R1.pdf. Ver página 11.
- [43] Ehud Karpas, Omri Abend, Yonatan Belinkov, Barak Lenz, Opher Lieber, Nir Ratner, Yoav Shoham, Hofit Bata, Yoav Levine, Kevin Leyton-Brown, Dor Muhlgay, Noam Rozen, Erez Schwartz, Gal Shachaf, Shai Shalev-Shwartz, Amnon Shashua, and Moshe Tenenholz. MRKL systems: A modular, neuro-symbolic architecture that combines large language models, external knowledge sources and discrete reasoning. URL: <http://arxiv.org/abs/2205.00445>. Ver página 11.
- [44] Yingqiang Ge, Wenyue Hua, Kai Mei, Jianchao Ji, Juntao Tan, Shuyuan Xu, Zelong Li, and Yongfeng Zhang. OpenAGI: When LLM meets domain experts. Ver página 11.
- [45] Mingchen Zhuge, Haozhe Liu, Francesco Faccio, Dylan R. Ashley, Róbert Csordás, Anand Gopalakrishnan, Abdullah Hamdi, Hasan Abed Al Kader Hammoud, Vincent Herrmann, Kazuki Irie, Louis Kirsch, Bing Li, Guohao Li, Shuming Liu, Jinjie Mai, Piotr Piękos, Aditya Ramesh, Imanol Schlag, Weimin Shi, Aleksandar Stanić, Wenyi Wang, Yuhui Wang, Mengmeng Xu, Deng-Ping Fan, Bernard Ghanem, and Jürgen Schmidhuber. Mindstorms in natural language-based societies of mind. URL: <http://arxiv.org/abs/2305.17066>. Ver página 11.
- [46] Yilun Du, Shuang Li, Antonio Torralba, Joshua B Tenenbaum, and Igor Mordatch. Improving factuality and reasoning in language models through multiagent debate. Ver página 11.
- [47] Chen Qian, Wei Liu, Hongzhang Liu, Nuo Chen, Yufan Dang, Jiahao Li, Cheng Yang, Weize Chen, Yusheng Su, Xin Cong, Juyuan Xu, Dahai Li, Zhiyuan Liu, and Maosong Sun. ChatDev: Communicative agents for software development. URL: <http://arxiv.org/abs/2307.07924>. Ver página 11.
- [48] Sirui Hong, Mingchen Zhuge, Jiaqi Chen, Xiawu Zheng, Yuheng Cheng, Ceyao Zhang, Jinlin Wang, Zili Wang, Steven Ka Shing Yau, Zijuan Lin, Liyang Zhou, Chenyu Ran, Lingfeng Xiao, Chenglin Wu, and Jürgen Schmidhuber. MetaGPT: Meta programming for a multi-agent collaborative framework. URL: <http://arxiv.org/abs/2308.00352>. Ver página 11.
- [49] Eirini Kalliamvakou. Research: quantifying GitHub copilot’s impact on developer productivity and happiness. URL: <https://github.blog/news-insights/research/research-quantifying-github-copilots-impact-on-developer-productivity-and-happiness/>. Ver página 12.
- [50] GitHub copilot features. URL: <https://docs-internal.github.com/en/copilot/about-github-copilot/github-copilot-features>. Ver página 12.

- [51] sourcegraph/scip. original-date: 2022-05-10T13:18:47Z. URL: <https://github.com/sourcegraph/scip>. Ver página 12.
- [52] sourcegraph/sourcegraph-public-snapshot: Code AI platform with code search & cody. URL: <https://github.com/sourcegraph/sourcegraph-public-snapshot>. Ver página 12.
- [53] Kamal Acharya. Devin: A cautionary tale of the autonomous AI engineer. URL: <https://medium.com/@lotussavy/devin-a-cautionary-tale-of-the-autonomous-ai-engineer-e1339ede8f8a>. Ver página 12.
- [54] Building a better repository map with tree sitter. URL: <https://aider.chat/2023/10/22/repomap.html>. Ver página 12.
- [55] Number of parameters in GPT-4 (latest data). URL: <https://explodingtopics.com/blog/gpt-parameters>. Ver página 13.
- [56] Baian Chen, Chang Shu, Ehsan Shareghi, Nigel Collier, Karthik Narasimhan, and Shunyu Yao. FireAct: Toward language agent fine-tuning. URL: <http://arxiv.org/abs/2310.05915>. Ver página 13.
- [57] Aohan Zeng, Mingdao Liu, Rui Lu, Bowen Wang, Xiao Liu, Yuxiao Dong, and Jie Tang. AgentTuning: Enabling generalized agent abilities for LLMs. URL: <http://arxiv.org/abs/2310.12823>. Ver página 13.
- [58] Zehui Chen, Kuikun Liu, Qiuchen Wang, Wenwei Zhang, Jiangning Liu, Dahua Lin, Kai Chen, and Feng Zhao. Agent-FLAN: Designing data and methods of effective agent tuning for large language models. URL: <http://arxiv.org/abs/2403.12881>. Ver página 13.
- [59] Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang, and Weizhu Chen. LoRA: Low-rank adaptation of large language models. URL: <http://arxiv.org/abs/2106.09685>. Ver página 14.
- [60] C4 - abstractions. URL: <https://c4model.com/abstractions>. Ver página 32.
- [61] Qinyu Luo, Yining Ye, Shihao Liang, Zhong Zhang, Yujia Qin, Yaxi Lu, Yesai Wu, Xin Cong, Yankai Lin, Yingli Zhang, Xiaoyin Che, Zhiyuan Liu, and Maosong Sun. RepoAgent: An LLM-powered open-source framework for repository-level code documentation generation. URL: <http://arxiv.org/abs/2402.16667>. Ver página 34.